INFORME FINAL

Detección de fraude en tarjetas de crédito: priorización de la cola de revisión

Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad N.º 9 — Proyecto Final Integrador

Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis
Marco Garcia · Esteban Derghazarian

Octubre 2026

Índice

1. Resumen ejecutivo — 2. Definición del problema y relevancia — 3. Datos y metodología — 4. Modelado y evaluación — 5. Interpretación del modelo — 6. Impacto en el negocio, riesgos y ética — 7. Conclusiones y recomendaciones — Anexos

1. Resumen ejecutivo

Problema. Un emisor de tarjetas debe decidir qué operaciones revisar a mano. Entre 284.807 transacciones reales solo 492 son fraude (0,17 %). Revisar todo es imposible; revisar al azar casi nunca encuentra un fraude.

Solución. Un modelo (Random Forest) que ordena las operaciones por riesgo para que el equipo revise primero las más sospechosas. Es una **cola de revisión priorizada**, no un "sí/no" automático.

Indicador (test aleatorio, 95 fraudes)	Revisión al azar	Regla "monto alto"	Modelo (Random Forest)
Fraudes hallados revisando 100 operaciones	≈ 0	0	77 de 95
Fraudes hallados revisando 500 operaciones	≈ 1	2	80 de 95
Con el umbral operativo	—	—	75 alertas, 70 fraudes (93 % de aciertos)
Valor neto estimado (test, 2 días)	—	€664	€8.530

Tabla 1. Con el mismo esfuerzo de revisión el modelo encuentra decenas de fraudes donde una regla simple encuentra uno o dos.

Resultado. Revisando las 100 operaciones de mayor riesgo se encuentran 77 de 95 fraudes (81,1 %); con el umbral operativo se emiten solo 75 alertas y 93 % de ellas son fraudes reales. Sobre operaciones futuras (test temporal) la señal se mantiene (PR-AUC 0,814 vs 0,804). El criterio inicial "FPR ≤ 5 %" habría exigido 2.920 revisiones y un resultado económico negativo.

Recomendación. Usar el score para ordenar la cola, fijar el umbral según la capacidad del equipo y revalidar con datos propios del emisor antes de operar.

Glosario	
PR-AUC	Calidad del ordenamiento cuando el fraude es muy raro (1 = perfecto; el azar da ≈ 0,002).
Top-K	Se toman las K operaciones con mayor score y se cuenta cuántos fraudes contienen.
FPR	Porcentaje de operaciones legítimas que se marcan como sospechosas.

2. Definición del problema y relevancia

La pregunta de negocio no es "¿esta transacción es fraude con certeza?", sino **a qué operaciones asignar primero un cupo limitado de revisión humana**. Cada fraude no detectado es pérdida financiera; cada falsa alarma consume tiempo de analista y puede bloquear a un cliente legítimo.

Objetivo medible. Maximizar los fraudes encontrados por cada operación revisada: PR-AUC, Recall y Precision como métricas técnicas y captura en Top-100 / Top-500 como métrica de negocio. Un orden aleatorio encontraría 0,17 fraudes cada 100 revisiones; el modelo debe multiplicar ese valor.

Cómo cambió el objetivo respecto de la pre-entrega. La pre-entrega fijó “Recall ≥ 80 % con FPR ≤ 5 %”. La devolución del tutor mostró que con 56.651 legítimas en el test, un FPR de 5 % equivale a ~2.832 alertas falsas: un KPI inoperable. Se reemplazó por Precision, cantidad de alertas y captura Top-K; el Recall se sigue reportando.

Tema	Pre-entrega	Informe final (y motivo)
KPI	Recall ≥ 80 % y FPR ≤ 5 %	PR-AUC, Recall, Precision y Top-K; FPR 5 % implica miles de alertas falsas
Selección del modelo	CV de 5 folds	Igual: CV de 5 folds sobre el 80 % de desarrollo, sin usar el test
Umbral	“Threshold tuning”	Máximo F1 sobre predicciones out-of-fold (no se ajusta con el test)
Variables de tiempo y monto	Escalar Time y Amount	Amount_log + hora cíclica: Time crudo toma valores nunca vistos en el test temporal
LightGBM	is_unbalance	Peso √(neg/pos): is_unbalance era inestable (PR-AUC ≈ 0)
Duplicados / desbalance	Pendientes	1.081 duplicados eliminados; class_weight y SMOTE dentro del Pipeline

Tabla 2. Trazabilidad de decisiones entre la pre-entrega y el informe final.

Hipótesis. H1: las componentes PCA (V1–V28) concentran la señal. H2: el monto en escala logarítmica ayuda a calibrar el riesgo. H3: un split aleatorio sobreestima el desempeño frente a uno temporal. Su resultado se discute en las secciones 4, 5 y 7.

3. Datos y metodología

3.1 Fuente y calidad

Credit Card Fraud Detection, ULB Machine Learning Group / Kaggle (Dal Pozzolo et al., 2015), licencia ODbL v1.0: transacciones de titulares europeos en septiembre de 2013 (dos días, 48 h). 284.807 filas × 31 columnas; tasa de fraude 0,173 %. El CSV se descarga de un mirror público y se valida al cargar.

Hallazgo de calidad	Decisión y motivo
0 nulos	Ninguna imputación necesaria.
1.081 duplicados exactos (19 eran fraudes)	Eliminados; quedan 283.726 filas y 473 fraudes. Evita que un mismo registro caiga en train y test.
Monto sesgado (mediana fraude €9,82; máximo €25.691)	Amount_log = log1p(Amount); el monto crudo no entra al modelo.
V1–V28 son componentes PCA anonimizadas	Se usan sin transformar; limitan la interpretación causal.
Time en segundos (0–172.792)	Se reemplaza por la hora del día (seno/coseno); se usa para el split temporal.
Desbalance 0,17 %	class_weight / scale_pos_weight; SMOTE solo dentro del Pipeline.

Tabla 3. Decisiones de calidad de datos (detalle cronológico en data_log.md).

3.2 Hallazgos del EDA

Las variables más asociadas al fraude son V17 (-0,31), V14 (-0,29) y V12 (-0,25). El monto por sí solo no separa: la mediana de un fraude es €9,82 contra €22,00 de una operación legítima. La madrugada concentra más fraude: 0,48 % entre 0 y 6 h contra 0,14 % el resto del día. La prevalencia también varía entre tramos temporales (0,08 % a 0,33 %). Un clasificador trivial “todo legítimo” tendría exactitud 99,83 % sin detectar ningún fraude, por eso no se usa Accuracy.

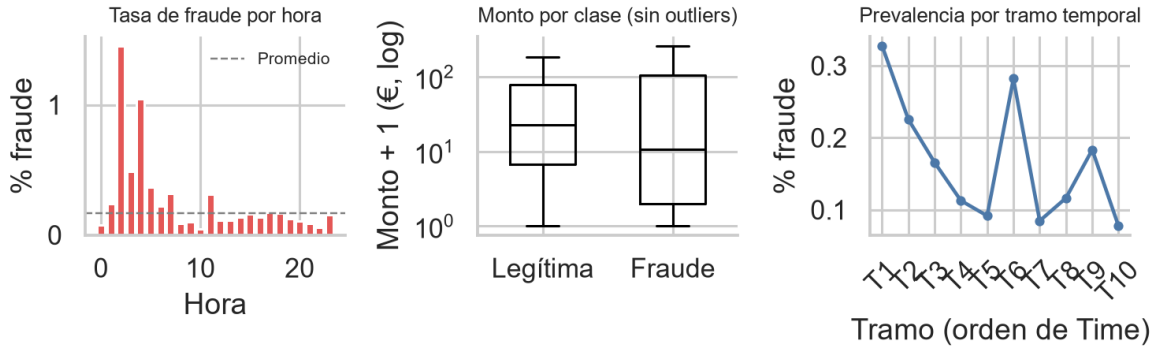


Figura 1. Tasa de fraude por hora, monto por clase y prevalencia por tramo temporal.

3.3 Metodología (CRISP-DM)

Se siguió CRISP-DM: negocio (sección 2), datos (esta sección), modelado y evaluación (sección 4) y traducción a una decisión (secciones 5–6). Todo el preprocesamiento vive en un Pipeline (escalado y, cuando se usa, SMOTE), de modo que nunca ve datos de validación ni de test. random_state = 42.

Etapa	Datos	Para qué se usa
Desarrollo	80 % aleatorio estratificado (226.980 filas, 378 fraudes)	CV de 5 folds para elegir modelo y umbral (out-of-fold)
Test estable	20 % restante (56.746 filas, 95 fraudes)	Evaluación final, una sola vez
Test temporal	Entrena con el primer 80 % por Time; prueba con el último 20 % (74 fraudes)	¿Generaliza hacia operaciones futuras?

Tabla 4. Diseño de validación. El test nunca interviene en la elección del modelo ni del umbral.

4. Modelado y evaluación

4.1 Algoritmos y regla de selección

Se compararon cinco configuraciones, todas con manejo del desbalance: Regresión Logística (baseline, class_weight), Random Forest, XGBoost (scale_pos_weight), LightGBM (peso √(neg/pos)) y XGBoost + SMOTE. **Regla fijada antes de mirar los tests:** 1) gana la mayor PR-AUC media en CV; 2) los modelos a menos de un desvío de la mejor quedan empatados; 3) entre los empatados se elige la mayor Precision@100 de CV.

Modelo	PR-AUC (CV)	± desvío	Precision@100 (CV)	Tiempo (s)
Logística	0,740	0,025	62,6 %	1
Random Forest *	0,828	0,041	64,4 %	100
XGBoost	0,850	0,036	64,2 %	24
LightGBM	0,830	0,034	63,2 %	9
XGBoost + SMOTE	0,845	0,034	63,8 %	26

*Tabla 5. Validación cruzada (5 folds) sobre el set de desarrollo. *Elegido: Random Forest.*

La logística queda claramente atrás (0,740). Los cuatro modelos de árboles (Random Forest, XGBoost, LightGBM, XGBoost + SMOTE) quedan empatados dentro de un desvío: **sus diferencias son menores que el ruido de la validación**. Por la regla se elige **Random Forest**; no hay evidencia de que sea mejor que los otros tres, y esa es una limitación (95 fraudes en el test).

4.2 Test estable y métrica de negocio Top-K

Modelo	PR-AUC	ROC-AUC	Fraudes@100	Fraudes@500	Recall@100	Precision@500
Ranking aleatorio	0,002	0,477	0	1	0,0 %	0,2 %
Regla: monto alto	0,003	0,451	0	2	0,0 %	0,4 %
Logística	0,681	0,964	74	80	77,9 %	16,0 %
Random Forest *	0,804	0,971	77	80	81,1 %	16,0 %
XGBoost	0,813	0,972	77	82	81,1 %	16,4 %
LightGBM	0,801	0,968	75	79	78,9 %	15,8 %
XGBoost + SMOTE	0,806	0,980	75	81	78,9 %	16,2 %

*Tabla 6. Test estable (56.746 operaciones, 95 fraudes). *Modelo elegido.*

Revisando las 100 operaciones de mayor score se encuentran **77 de 95** fraudes (Precision@100 = 77,0 %; 460 veces la tasa base). Ampliar a 500 revisiones suma solo 3 fraudes más: la curva se aplana, el valor está en el tope del ranking. La regla estática “monto alto” encuentra 2 fraudes en 500 revisiones: el monto no sirve para priorizar.

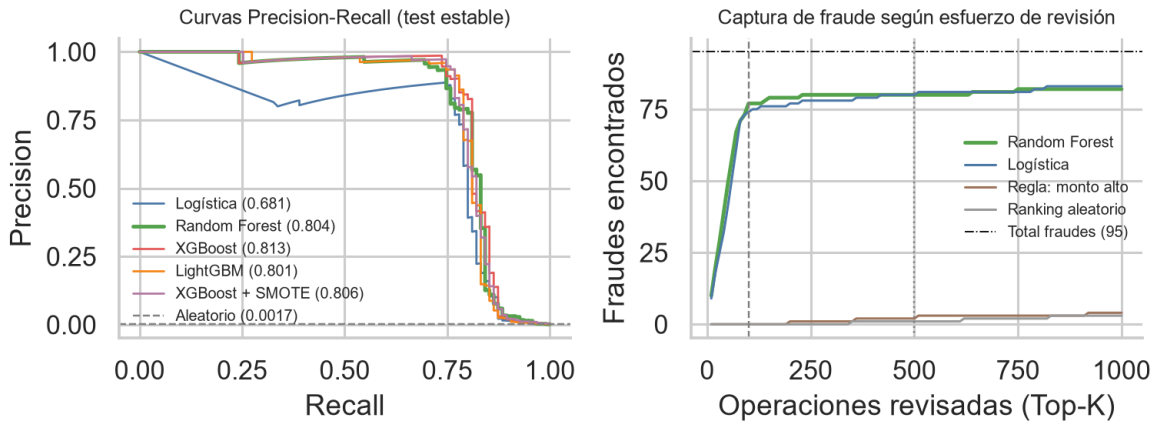


Figura 2. Curvas Precision-Recall y fraudes encontrados según operaciones revisadas.

4.3 Umbral operativo y carga de revisión

El umbral sale de las predicciones out-of-fold del set de desarrollo (máximo F1): **0,569**. Aplicado al test estable emite **75 alertas** (70 fraudes, 5 falsas): Precision 93,3 %, Recall 73,7 %. En el test temporal emite 53 alertas, Precision 98,1 % y Recall 70,3 %. El criterio FPR = 5 % de la pre-entrega daría 2.920 alertas con Precision 3,0 %. Con el umbral operativo el Recall (74 %) queda por debajo de la meta inicial del 80 %; se alcanza revisando las 100 operaciones de mayor riesgo (81 %) o bajando el umbral a costa de más alertas. Es una decisión de capacidad del equipo.

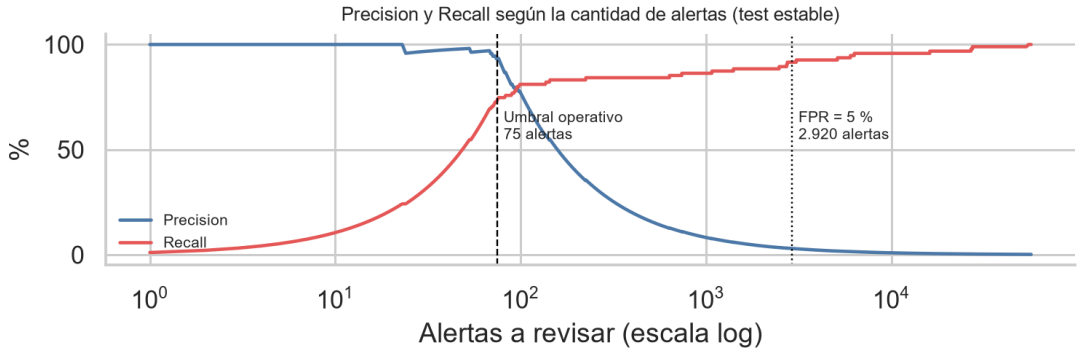


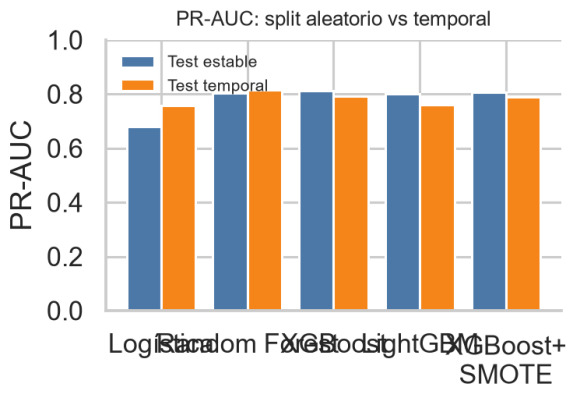
Figura 3. Precision y Recall según la cantidad de alertas a revisar (escala logarítmica).

4.4 Validación temporal

Se ordenó por Time y se entrenó con las primeras 226.980 operaciones (399 fraudes) para probar con las 56.746 posteriores (74 fraudes; desde la hora 40). Es el diseño más cercano a producción: el modelo no ve el futuro.

Modelo	PR-AUC estable	PR-AUC temporal	Diferencia	Fraudes@100 temporal	Fraudes@500 temporal
Logística	0,681	0,757	0,077	59	64
Random Forest *	0,804	0,814	0,011	60	64
XGBoost	0,813	0,791	-0,022	58	63
LightGBM	0,801	0,762	-0,039	58	63
XGBoost + SMOTE	0,806	0,789	-0,017	58	61

*Tabla 7. Estable vs temporal. *Modelo elegido. En el temporal gana Random Forest (PR-AUC 0,814).*



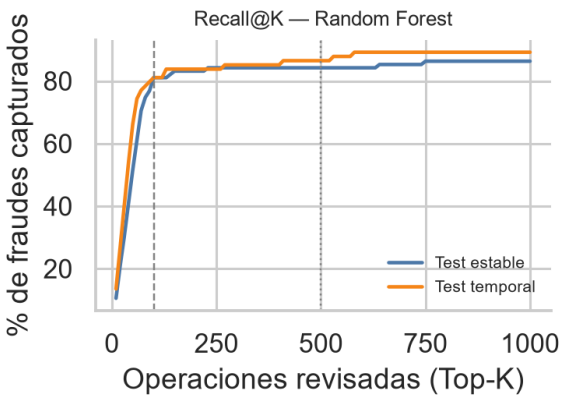


Figura 4. PR-AUC por modelo en ambos esquemas y porcentaje de fraudes capturado según K.

Entre el test estable y el temporal, Random Forest pasa de PR-AUC 0,804 a 0,814 (suba de 0,011) y el Recall@100 de 81,1 % a 81,1 %. Los fraudes absolutos del Top-100 bajan (77 → 60) sobre todo porque el test temporal tiene menos fraudes (74 vs 95). **H3 no se confirma con claridad:** no se observa una degradación relevante hacia el futuro; la diferencia es menor que el ruido (con 74 fraudes, un fraude más o menos mueve varios puntos). El temporal sigue siendo el piso más honesto para decidir un piloto, porque es lo que ocurriría en producción.

5. Interpretación del modelo

Se calcularon valores SHAP sobre una muestra de 695 operaciones. Las variables que más pesan son V14, V12, V10, V4, las mismas que destaca el EDA: **H1 queda respaldada**. Como las V* son componentes PCA anonimizadas, el negocio no puede traducir “sube V14” a una regla de comercio o país: el modelo prioriza, no explica ante un auditor. En un emisor real habría que sumar variables interpretables (MCC, dispositivo, geografía, historial).

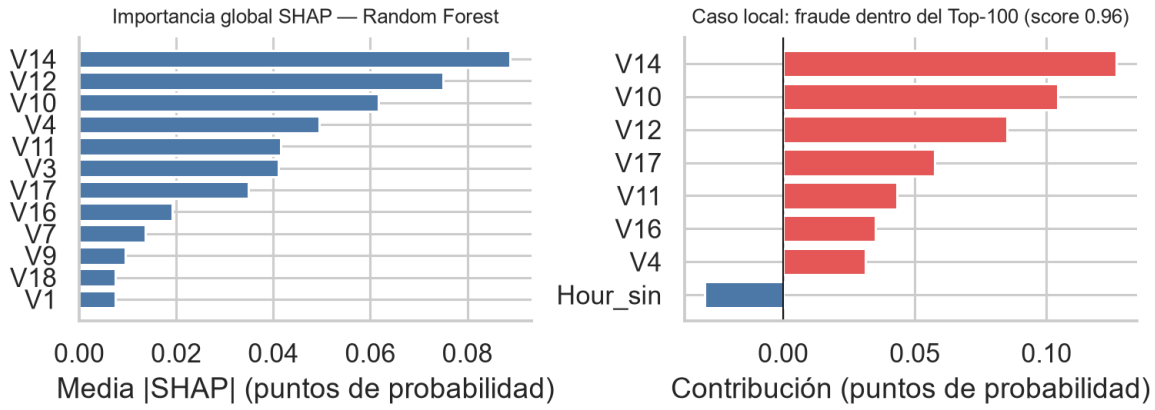


Figura 5. Importancia global (SHAP) y explicación de un fraude concreto dentro del Top-100.

Ablaciones. Para probar H2 se reentrenó el modelo elegido quitando variables:

Variante de variables	PR-AUC estable	Fraudes@100 estable	PR-AUC temporal	Fraudes@100 temporal
Modelo completo	0,804	77	0,814	60
Sin monto (Amount_log)	0,800	76	0,808	59
Sin hora del día	0,799	77	0,819	60
Solo V1–V28	0,802	76	0,810	59
Time crudo en lugar de hora	0,800	76	0,819	59

Tabla 8. Ninguna variante se separa del modelo completo más de lo que permite el ruido.

Sin el monto el PR-AUC estable es 0,800 contra 0,804 del modelo completo, y sin la hora 0,799. **H2 no se sostiene**: el monto no aporta de forma medible; la señal está en V1–V28. Se conservan Amount_log y la hora por su valor de negocio (y porque no

perjudican), no por ganancia de desempeño. Tampoco se calibró el score: sirve para ordenar, no como probabilidad.

6. Impacto en el negocio, riesgos y ética

Escenario económico. Supuesto explícito: cada revisión manual cuesta €5 (no hay costos reales del emisor). El beneficio es el monto de los fraudes detectados; el neto resta el costo de revisión. El monto total de fraude en el test es €14.766.

Escenario (test, 2 días)	Alertas	Fraudes	Precision	Monto detectado	Costo revisión	Neto
Regla estática: Top-500 por monto	500	2	0,4 %	€3.164	€2.500	€664
Modelo: Top-100	100	77	77,0 %	€10.981	€500	€10.481
Modelo: Top-500	500	80	16,0 %	€11.708	€2.500	€9.208
Modelo: umbral operativo	75	70	93,3 %	€8.905	€375	€8.530
Modelo: umbral con FPR = 5 %	2.920	87	3,0 %	€13.893	€14.600	-€707

Tabla 9. El valor está en ordenar la cola, no en umbrales holgados de FPR.

Con el umbral operativo el modelo detecta €8.905 con 75 revisiones (neto €8.530); la regla de monto alto neto €664 con 500 revisiones, y el criterio FPR = 5 % pierde €707. Extrapolando el volumen del test a un día de operación, el umbral operativo implica ~187 alertas por día. Son órdenes de magnitud de un dataset de 2013, no una proyección financiera.

Auditoría por segmentos. Con el umbral operativo el Recall es 50 % en “€1–10” (monto), el segmento más débil con al menos 10 fraudes; en la madrugada es 81 %. Con 95 fraudes los segmentos son pequeños: es una alerta para monitorear, no una conclusión.

Riesgo	Mitigación
Dataset de 2 días (2013), solo Europa	Tratar el caso como prueba de método; reentrenar con datos del emisor.
Deriva de los patrones de fraude	Monitorear PR-AUC, Precision y captura@K por día; reentrenar periódicamente.
PCA poco explicable ante auditoría	Usar el score solo para priorizar; sumar reglas y variables nativas.
Falso positivo = bloqueo de un cliente	Umbral según capacidad; canal de apelación; sin rechazo automático.
Fuga de información (SMOTE/escalado)	Pipeline único; test separado antes de cualquier ajuste; selección solo con CV.
Privacidad	Datos ya anonimizados, sin PII; minimización y acceso restringido al score.

Tabla 10. Riesgos y mitigaciones. El prototipo no autoriza un despliegue automático.

Ética y escalabilidad. No hay datos personales. Un falso negativo pierde dinero y un falso positivo daña al cliente; por eso se reportan ambos y el volumen absoluto de alertas. Cualquier uso real requeriría supervisión humana, registro de cada alerta y revisión legal. Escalar implica puntuar en lote o en línea, reentrenar con ventanas nuevas y medir la deriva; el entrenamiento completo toma minutos en una computadora común.

7. Conclusiones y recomendaciones

• El problema se formuló como **priorización bajo capacidad limitada**: PR-AUC, Recall, Precision y Top-K reflejan esa decisión mejor que Accuracy o un FPR suelto.

• Los modelos de árboles (incluido Random Forest, elegido por CV) superan a la logística (en CV y en el test estable) y a las reglas simples; entre ellos no hay diferencias distinguibles del ruido.

• En el test estable, el Top-100 encuentra 77 de 95 fraudes y el umbral operativo emite 75 alertas con 93 % de aciertos.

• H1 (señal en V1–V28) se confirma; H2 (monto útil) no; H3 (aleatorio optimista) no se confirma con claridad.

• SMOTE no mejora al modelo sin remuestreo: su costo no se justifica en este dataset.

• **Recomendación:** no desplegar a ciegas. Usar el score para ordenar la cola, fijar el umbral según el turno de analistas, reentrenar con datos actuales del emisor y medir captura@100/@500 y deriva en una ventana temporal nueva.

Anexos

Anexo A. Trazabilidad con la consigna

Peso	Criterio	Dónde está en este informe
20 %	Problema y negocio	§1–2: ranking, costos FP/FN, KPI Top-K, cambio de KPI (Tabla 2)
20 %	Datos y metodología	§3: calidad, EDA, Pipeline, CRISP-DM, tres esquemas de validación
15 %	Selección del modelo	§4.1 y Tablas 5–7: regla fijada antes del test
15 %	Calidad de métricas	PR-AUC, Recall, Precision, F1, Top-K, alertas, CV y test temporal
15 %	Interpretación y valor	§5–6: SHAP, ablaciones y escenario económico (Tabla 9)
5 %	Ética y privacidad	§6 y Tabla 10
10 %	Claridad	Resumen con glosario, tablas y figuras

Tabla A1. Cobertura de los criterios de evaluación.

Anexo B. Reproducibilidad y fuentes

Código: notebook *notebooks/TP_Final_Deteccion_Fraude.ipynb* (ejecutable en Colab), que genera *results/* (tablas, figuras y results.json); este informe se arma con *scripts/build_informe.py* a partir de esos resultados. Dependencias en *requirements.txt*. Repositorio: https://github.com/SolKidonakis/TP_Final_DataScience

Dal Pozzolo, A., Caelen, O., Johnson, R. A. y Bontempi, G. (2015). *Calibrating Probability with Undersampling for Unbalanced Classification*. IEEE CIDM. Dataset: Credit Card Fraud Detection (ULB), licencia ODbL v1.0. Chapman, P. et al. (2000). *CRISP-DM 1.0*.