INFORME FINAL

Detección de fraude en tarjetas de crédito: priorización de la cola de revisión

Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad N.º 9 — Proyecto Final Integrador

Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis
Marco Garcia · Esteban Derghazarian

Octubre 2026

Repositorio del equipo

https://github.com/SolKidonakis/TP_Final_DataScience

Índice

1. Resumen ejecutivo — 2. Definición del problema y relevancia — 3. Datos y metodología — 4. Modelado y evaluación — 5. Interpretación del modelo — 6. Impacto en el negocio, riesgos y ética — 7. Conclusiones y recomendaciones — Anexos

1. Resumen ejecutivo

Problema: Un emisor de tarjetas (audiencia: Prevención de Fraude) debe decidir qué operaciones revisar a mano. El dataset ULB tiene 284.807 transacciones y solo 492 fraudes (0,172 %). Con tan pocos positivos, un FPR del 5 % sobre las ~56.651 legítimas del holdout produciría unas 2.832 alertas falsas. No alcanza con controlar FPR: hay que mirar Precision y cuántas operaciones revisaría el equipo.

Solución: Un modelo candidato XGBoost, elegido por la mayor PR-AUC media de una validación cruzada estratificada de 5 folds (PR-AUC 0,853 ± 0,036). El producto no es un "sí/no" rígido, sino una cola de revisión: el equipo mira primero las operaciones de mayor riesgo. La selección se contrastó después con un holdout aleatorio estratificado y una validación temporal por Time.

Indicador (holdout)	Azar / sin modelo	XGBoost aleatorio	RandomForest temporal
PR-AUC	≈ 0,002 (tasa base)	0,813	0,815
Recall (umbral 0,5)	—	77,9 %	74,3 %
Precision (umbral 0,5)	—	85,1 %	90,2 %
Fraudes en Top-100	≈ 1	77	60
Fraudes en Top-500	≈ 1	81	65
Alertas con umbral operativo	miles (si FPR=5 %)	79	ver §4.4

Tabla 1. Lectura de negocio: captura de fraude con el mismo esfuerzo de revisión.

Resultado: En holdout aleatorio (95 fraudes en 56.746 operaciones), XGBoost alcanza PR-AUC 0,813, Recall 77,9 % y Precision 85,1 %. Si el equipo revisa las 100 operaciones de mayor riesgo encuentra 77 fraudes (Precision@100 = 77,0 %); con 500 revisiones, 81 fraudes (lift 96,8×). Con umbral operativo 0,81 emite 79 alertas (74 TP / 5 FP).

Límite y recomendación: En validación temporal el mejor modelo es RandomForest (PR-AUC 0,815; Top-100 = 60 fraudes). La señal se sostiene, pero el split aleatorio es algo más optimista. Se recomienda usar el score para priorizar la cola, fijar el umbral según la capacidad del equipo y revalidar en ventanas temporales nuevas antes de un despliegue real.

2. Definición del problema y relevancia

La pregunta de negocio no es "¿esta transacción es fraude con certeza?", sino **a qué operaciones asignar primero un cupo limitado de revisión humana**. El producto es un ranking. La relevancia es directa: cada fraude no detectado es pérdida financiera y cada falsa alarma consume analista y puede bloquear a un cliente legítimo.

Objetivo medible (fijado en la pre-entrega y ajustado por la devolución): maximizar Recall de fraude manteniendo Precision y un volumen de alertas operable. Métricas principales: PR-AUC, Recall y Precision. Métrica de negocio: captura en Top-100 y Top-500. Benchmark: un orden aleatorio captura, en el holdout, unos 1 fraudes entre 100 revisiones; el modelo debe multiplicar ese lift.

Situación	Lectura estadística	Costo de negocio
Alerta sobre operación legítima	Falso positivo	Horas de analista + fricción al cliente
Fraude que no entra a la cola	Falso negativo	Pérdida del monto y daño reputacional
FPR ≤ 5 % como única traba	Miles de FP con 0,17 % de prevalencia	El equipo no puede revisar esa cola

Tabla 2. Costos del error. El umbral es una decisión de capacidad, no un default técnico.

Hipótesis

H1: los componentes PCA (V1–V28) concentran señal discriminativa. H2: el monto, transformado a escala logarítmica, aporta menos que las V* pero ayuda a calibrar riesgo. H3: como existe Time, un split aleatorio puede sobreestimar el desempeño; entrenar con operaciones anteriores y probar con posteriores es la prueba más realista.

3. Datos y metodología

3.1 Fuente y calidad

Credit Card Fraud Detection, ULB Machine Learning Group / Kaggle (Dal Pozzolo, Caelen, Johnson y Bontempi, 2015). Licencia ODbL v1.0. Transacciones de titulares europeos en septiembre de 2013 (dos días). Archivo original: 284.807 filas × 31 columnas. Tasa de fraude: 0,172 %. El CSV se descarga de un mirror público y se cachea en data/creditcard.csv; el esquema se valida al cargar (Time, V1–V28, Amount, Class).

Hallazgo de calidad	Decisión y motivo
0 nulos	Ninguna imputación.
1.081 duplicados exactos (19 fraudes)	Eliminados; quedan 283.726 filas y 473 fraudes.
Amount sesgado (media €88; mediana €22)	Amount_log = log1p(Amount); el crudo no entra al modelo.
V1–V28 ya son PCA anonimizado	Se usan sin reescalar; limitan interpretación causal.
Time en [0 ; 172.792] s	Sirve para el split temporal; en el modelo se reemplaza por hora cíclica (Hour_sin, Hour_cos).
Desbalance 0,17 %	class_weight / scale_pos_weight; SMOTE (strategy=0,1) solo dentro del Pipeline.

Tabla 3. Decisiones de calidad registradas (equivalente a un data log).

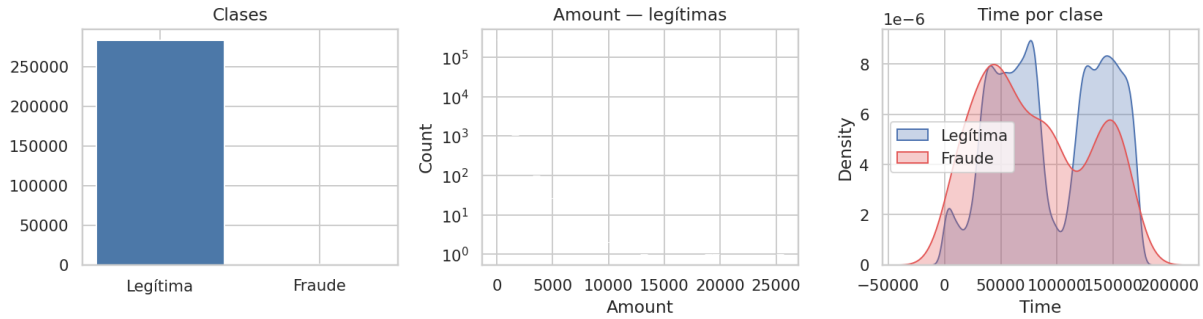


Figura 1. Distribución de clases, Amount de las legítimas y Time por clase.

3.2 Conclusiones del EDA

Las variables con mayor |correlación| con Class son V17 (0,31), V14 (0,29) y V12 (0,25). Amount por sí solo no separa bien: hay fraudes en montos bajos y medios. Time muestra concentraciones distintas por clase, lo que respalda H3. Accuracy o ROC-AUC aislados son engañosos: un clasificador trivial “todo legítimo” tendría Accuracy 99,83 % y no detectaría ningún fraude.

3.3 Preparación y CRISP-DM

Se siguió CRISP-DM. Todas las transformaciones viven en un Pipeline de scikit-learn / imbalanced-learn: StandardScaler sobre Amount_log; V1–V28 y la hora cíclica pasan sin cambios; SMOTE, cuando se usa, queda dentro del pipeline. random_state=42.

Diseño de validación	Pregunta que responde
CV estratificada 5-fold sobre el train (80 %)	¿Qué modelo discrimina mejor (PR-AUC) sin mirar el test?
Holdout estratificado 80/20 (una sola vez)	¿Cuánto rinde en una mezcla i.i.d. de las 48 h?
Split temporal por Time (80 % anterior → 20 % posterior)	¿Generaliza hacia operaciones futuras?

Tabla 4. Tres diseños de validación. El test no interviene en la elección del modelo ni del umbral.

4. Modelado y evaluación

4.1 Algoritmos y regla de selección

Se compararon cinco configuraciones, todas con manejo explícito del desbalance: Regresión Logística (baseline, class_weight=balanced), Random Forest (class_weight), XGBoost (scale_pos_weight), LightGBM (peso √(neg/pos) y regularización) y XGBoost+SMOTE dentro del pipeline. **Regla fijada antes de mirar los holdouts:** gana el mayor PR-AUC medio de la CV de 5 folds sobre el train. El desempate lo dan Precision@100 de CV, Recall y el volumen de alertas. El split temporal no cambia la regla: sirve para medir robustez.

Modelo	PR-AUC media	Desvío	Precision@100 media	Recall 0,5 media
XGBoost *	0,853	0,036	64,4 %	83,6 %
XGBoost + SMOTE	0,841	0,033	63,6 %	83,1 %
LightGBM	0,829	0,034	63,2 %	81,2 %
Random Forest	0,828	0,040	64,4 %	80,7 %
Logística	0,740	0,025	62,6 %	90,7 %

*Tabla 5. Validación cruzada 5-fold sobre el train aleatorio (226.980 operaciones, 378 fraudes). *Elegido: XGBoost (PR-AUC 0,853 ± 0,036).*

4.2 Holdout aleatorio

Modelo	PR-AUC	Recall	Precision	F1	Alertas	Fraud@100	Fraud@500
Logística	0,681	87,4 %	5,6 %	0,105	1.487	74	80
Random Forest	0,803	74,7 %	93,4 %	0,830	76	77	80
XGBoost *	0,813	77,9 %	85,1 %	0,813	87	77	81
LightGBM	0,801	77,9 %	90,2 %	0,836	82	75	79
XGBoost + SMOTE	0,811	77,9 %	78,7 %	0,783	94	75	80

*Tabla 6. Holdout aleatorio, umbral 0,5. *Candidato. Test: 56.746 operaciones, 95 fraudes.*

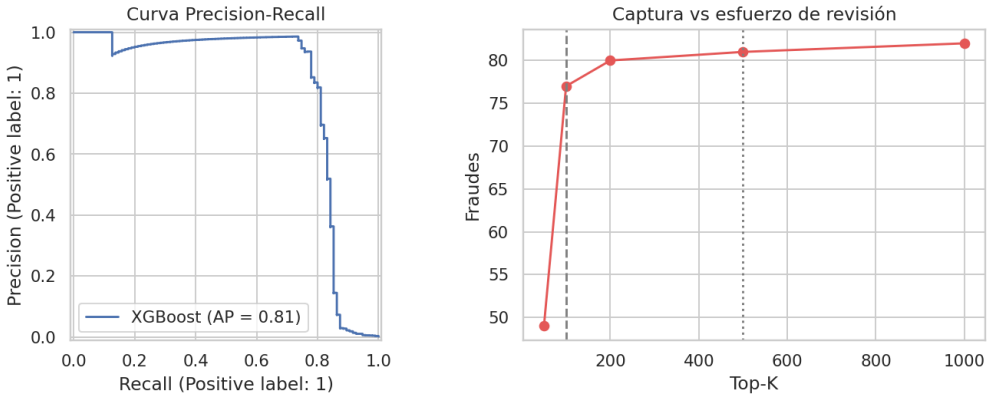


Figura 2. Curva Precision-Recall y captura Top-K de XGBoost en el holdout aleatorio.

4.3 Umbral operativo y carga de revisión

El umbral se fija con el máximo F1 sobre las predicciones out-of-fold del train (no se optimiza con el test): **0,81**. En el holdout emite **79 alertas** (74 TP / 5 FP / 21 FN): Precision 93,7 % y Recall 77,9 %. Esa es la carga real que tendría que revisar el equipo. Un FPR del 5 % costaría ~2.832 revisiones falsas.

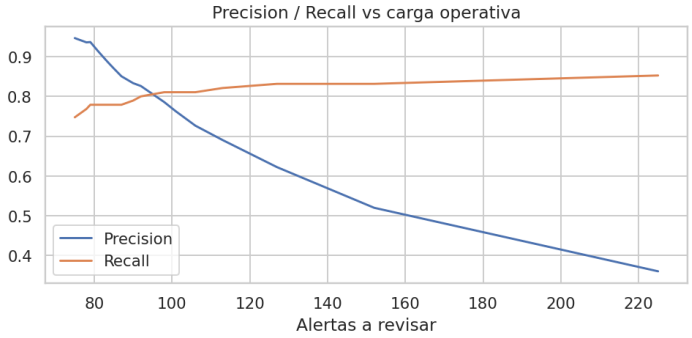


Figura 3. Precision y Recall en función del número de alertas.

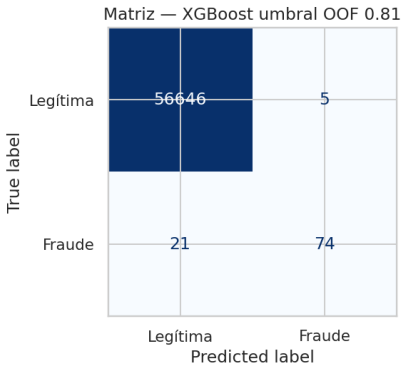


Figura 4. Matriz de confusión de XGBoost con umbral operativo 0,81.

4.4 Validación temporal versus aleatoria

Se ordenó por Time y se entrenó con las primeras 226.980 operaciones (399 fraudes) y se evaluó con las 56.746 posteriores (74 fraudes). Es el diseño que pide la devolución y el más cercano a producción: el modelo no ve el “futuro” de las 48 horas.

Modelo	PR-AUC	Recall	Precision	Fraud@100	Fraud@500
Logística	0,757	91,9 %	2,4 %	59	64
Random Forest *	0,815	74,3 %	90,2 %	60	65
XGBoost	0,798	75,7 %	80,0 %	58	63
LightGBM	0,762	74,3 %	75,3 %	58	63
XGBoost + SMOTE	0,785	77,0 %	74,0 %	57	61

*Tabla 7. Holdout temporal. *Mejor PR-AUC: RandomForest. Test: 74 fraudes.*

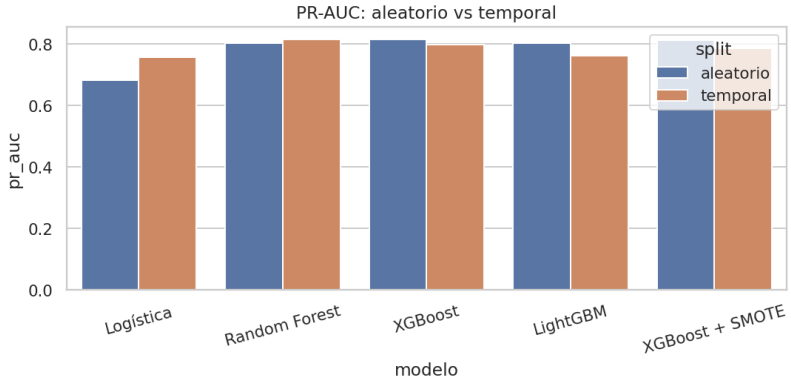


Figura 5. PR-AUC por modelo en ambos esquemas.

XGBoost sigue siendo competitivo en temporal (PR-AUC 0,798), pero RandomForest lo supera levemente y con Precision 90,2 %. La captura Top-100 baja de 77 a 60 fraudes, en parte porque el test temporal tiene menos positivos (74 vs 95). H3 queda respaldada: el aleatorio no miente, pero es el techo; el temporal es el piso más honesto para decidir un piloto.

5. Interpretación del modelo

Sobre XGBoost se leyeron importancias de split (no son causalidad ni SHAP), usando los nombres que produce el ColumnTransformer. Las V* más usadas coinciden con el EDA (V14, V17, V12 y vecinas). Hour_sin / Hour_cos y Amount_log aportan, pero no lideran. Como las V* son PCA, el negocio no puede traducir “sube V14” a una regla de comercio o país: el modelo prioriza, no explica el fraude ante un auditor.

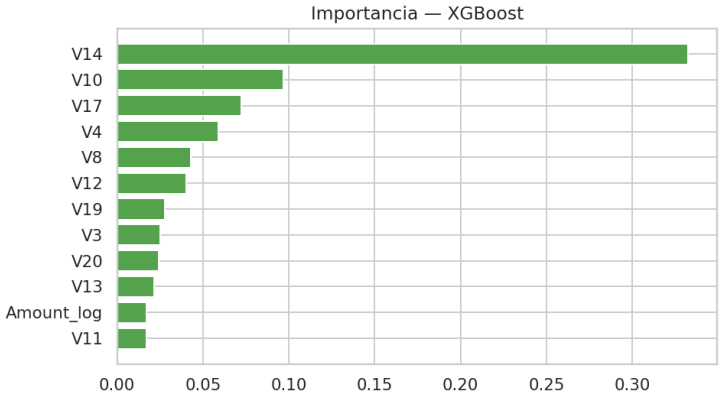


Figura 6. Importancia de variables de XGBoost (split aleatorio). Lectura descriptiva, no causal.

El score se usa para ordenar. Un valor 0,80 no se interpreta aquí como “probabilidad calibrada del 80 %”: no se reporta curva de calibración. Para un umbral de corte alcanza con el ranking y la matriz de confusión.

6. Impacto en el negocio, riesgos y ética

Sin ranking, capturar ~78 % de los fraudes del holdout exigiría revisar una fracción enorme de la cartera o convivir con miles de alertas. Con el modelo, ese Recall se obtiene revisando 79 operaciones, o 77 fraudes con solo 100 revisiones. Un FPR del 5 % costaría ~2.832 revisiones falsas; el umbral elegido cuesta 5 FP.

Escenario de revisión	Operaciones a mirar	Fraudes hallados	Precision
Azar (100 casos)	100	≈ 1	≈ tasa base
Modelo Top-100	100	77	77,0 %
Modelo Top-500	500	81	16,2 %
Umbral 0,81 (OOF)	79	74	93,7 %
Regla FPR = 5 %	~2.832+	alto Recall, baja Precision	muy baja

Tabla 8. El valor está en ordenar la cola, no en umbrales holgados de FPR.

Riesgo	Mitigación
Dataset de solo 2 días (2013), Europa	Tratar el caso como prueba de método; reentrenar con datos propios del emisor.
Drift de patrones de fraude	Monitorear PR-AUC, Precision y captura@K por día; reentrenar.
PCA poco explicable ante auditoría	Usar el score para priorizar; complementar con reglas y features nativas.
Falso positivo = bloqueo de cliente	Umbral según capacidad; canal de apelación; no automatizar el rechazo final.
Fuga si SMOTE o scaler ven el test	Pipeline único; CV y holdout separados antes de cualquier ajuste.
Privacidad	Datos ya anonimizados; minimización; acceso need-to-know al score.

Tabla 9. Riesgos y mitigaciones. El prototipo no autoriza un despliegue automático.

Ética

No hay PII. El umbral es una decisión explícita de negocio (Precision y cupo), no un default de 0,5. Un falso negativo pierde dinero; un falso positivo daña al cliente: por eso se reportan ambos y el volumen absoluto de alertas. Uso académico bajo ODbL.

7. Conclusiones y recomendaciones

- El problema se formuló como priorización bajo capacidad limitada. PR-AUC, Recall, Precision y captura Top-K reflejan esa decisión mejor que Accuracy o un FPR suelto.
- XGBoost es el candidato (mayor PR-AUC de CV: 0,853 ± 0,036). En holdout aleatorio: PR-AUC 0,813, Recall 77,9 %, Precision 85,1 %; Top-100 = 77 fraudes; umbral 0,81 → 79 alertas.
- H1 tiene respaldo descriptivo (V17, V14, V12). H3 también: en temporal gana RandomForest (PR-AUC 0,815) y la captura Top-100 baja a 60. El aleatorio es techo; el temporal es la prueba de piloto.
- SMOTE no se elige: sostiene Recall pero no mejora PR-AUC ni Precision respecto de XGBoost sin remuestreo.
- Recomendación: no desplegar a ciegas. Usar el score para ordenar la cola, fijar el umbral según el turno de analistas, reentrenar con datos actuales del emisor y medir captura@100/@500 y drift en una ventana temporal nueva.

Anexos

Anexo A. Trazabilidad con la consigna, la pre-entrega y la devolución

Peso	Criterio	Dónde está en este informe
20 %	Problema y negocio	§1–2: ranking, costos FP/FN, KPI Top-K
20 %	Datos y metodología	§3: calidad, EDA, Pipeline, CV y dos holdouts
15 %	Selección del modelo	§4.1 y Tablas 5–7 (regla: PR-AUC de CV)
15 %	Calidad de métricas	PR-AUC, Recall, Precision, Top-K, alertas
15 %	Interpretación y valor	§5–6: importancias y carga de revisión
5 %	Ética y privacidad	§6 y Tabla 9
10 %	Claridad	Resumen no técnico, figuras y recomendación

Tabla A1. Cobertura de los criterios de evaluación.

Pedido de la devolución	Estado
PR-AUC, Recall y Precision como métricas principales	Tablas 1, 6 y 7; no se decide por FPR.
Cuántas operaciones revisaría el equipo	§4.3: 79 alertas vs ~2.832 si FPR=5 %.
Captura si se revisan Top-100 / Top-500	Figura 2 y Tabla 8.
Comparar split aleatorio vs temporal por Time	§4.4, Figura 5, Tabla 7.
Validación cruzada para elegir el modelo	§4.1 y Tabla 5; el test no interviene.

Tabla A2. Cierre de la devolución del tutor.

Anexo B. Reproducibilidad y fuentes

Dal Pozzolo, A., Caelen, O., Johnson, R. A. y Bontempi, G. (2015). Calibrating Probability with Undersampling for Unbalanced Classification. IEEE CIDM. Dataset: Credit Card Fraud Detection (ULB). Licencia ODbL v1.0. Chapman, P. et al. (2000). CRISP-DM 1.0.