Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad N° 9 — Proyecto Final Integrador

PRE-ENTREGA

Detección de Fraude en Tarjetas de Crédito

Modelo de clasificación supervisada para identificación de transacciones fraudulentas

Grupo: 33

Integrantes: Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis · Marco Garcia · Esteban Derghazarian

Fecha de entrega: 21 de septiembre de 2026

1. Resumen Ejecutivo

El fraude en tarjetas de crédito genera pérdidas globales superiores a USD 33.000 millones anuales. El presente proyecto propone un **modelo de clasificación supervisada** que distinga transacciones fraudulentas de legítimas sobre datos históricos bancarios.

Audiencia: Área de Prevención de Fraude y Gestión de Riesgo Crediticio.

> **KPI de negocio: Recall ≥ 80 % sobre transacciones fraudulentas, manteniendo una Tasa de Falsos Positivos (FPR) ≤ 5 % sobre transacciones legítimas.**

2. Definición del Problema y Caso de Negocio

Elemento	Descripción
Objetivo medible	Clasificar cada transacción como fraudulenta (Clase 1) o legítima (Clase 0), maximizando el Recall y controlando la tasa de Falsos Positivos.
Hipótesis	Los patrones en monto, frecuencia temporal y componentes PCA permiten que un modelo ML supere a los sistemas de reglas estáticas de la industria.
Restricciones	Desbalance extremo de clases (0,172 % fraudes); variables V1–V28 anonimizadas por PCA; sin enriquecimiento externo; contexto académico sin datos en tiempo real.
Valor esperado	Reducir el monto de fraudes no detectados respecto al baseline de reglas simples y minimizar bloqueos innecesarios de clientes legítimos.

3. Relevamiento de Fuentes de Datos

3.1 Fuente

Atributo	Detalle
Nombre	Credit Card Fraud Detection
Origen	Kaggle / ULB Machine Learning Group
Licencia	Open Database License (ODbL v1.0) — uso libre para investigación
Tamaño	284.807 transacciones · 31 variables · ~150 MB (CSV)
Período	Septiembre 2013 — titulares europeos — 2 días
Clases	284.315 legítimas (99,83 %) / 492 fraudulentas (0,172 %)

3.2 Diccionario — 10 variables principales

Variable	Tipo	Descripción	Rango
Time	Float	Segundos desde la 1ª transacción	0 – 172.792
Amount	Float	Monto en euros (media: €88, mediana: €22)	0 – 25.691
Class	Binaria	*Target:* 1 = fraude, 0 = legítima	{0, 1}
V1	Float	1.° componente PCA (datos anonimizados)	[−56,4 ; 2,5]
V2	Float	2.° componente PCA	[−72,7 ; 22,1]
V3	Float	3.° componente PCA	[−48,3 ; 9,4]
V4	Float	4.° componente PCA	[−5,7 ; 16,9]
V5	Float	5.° componente PCA	[−113,7 ; 34,8]
V6	Float	6.° componente PCA	[−26,2 ; 73,3]
V7	Float	7.° componente PCA	[−43,6 ; 120,6]

3.3 Calidad de datos y decisiones de limpieza

Problema	Estado	Acción
Valores nulos	**Sin nulos**	Ninguna acción requerida.
Outliers en *Amount*	**Presentes**	**Tomada:** se aplicará transformación logarítmica.
Outliers en V1–V28	**Presentes**	**Pendiente:** evaluación con boxplot por clase.
Desbalance de clases	**Crítico**	**Tomada:** separación train/test estratificada 80/20 antes de preprocesamiento. **Pendiente:** elección entre SMOTE, undersampling o class_weight.
Duplicados	**Pendiente**	Verificación y eliminación de filas exactamente duplicadas.
Escalado	**Tomada**	StandardScaler sobre *Amount* y *Time* (V1–V28 ya están escaladas).

4. Plan de Modelado y Validación

4.1 Esquema de validación

Stratified K-Fold (5 folds) durante selección y tuning de modelos. **Holdout 20 %** estratificado, separado antes de todo preprocesamiento, reservado exclusivamente para la evaluación final.

4.2 Baseline y plan de experimentación

Experimento	Modelo	Manejo del desbalance
Exp. 1 (Baseline)	Regresión Logística	class_weight='balanced'
Exp. 2	Random Forest	class_weight + threshold tuning
Exp. 3	XGBoost	scale_pos_weight + threshold tuning
Exp. 4	LightGBM	is_unbalance + threshold tuning
Exp. 5	Mejor modelo	SMOTE dentro del pipeline de CV

4.3 Métricas, umbral de éxito y benchmark

Métrica	Rol	Umbral / Justificación
Recall (fraude)	KPI principal	≥ 0,80 en holdout
FPR	Restricción de negocio	≤ 0,05 en holdout
AUC-PR	Comparación de modelos	Superar baseline; más informativa que AUC-ROC en datos desbalanceados
Precision (fraude)	Complementaria	Control de alertas incorrectas
F1-Score (fraude)	Complementaria	Balance Precision–Recall
Matriz de confusión	Diagnóstico	Análisis errores Tipo I y II

4.4 Riesgos, limitaciones y próximos pasos

Riesgos identificados:

- Desbalance extremo puede sesgar modelos si SMOTE no se aplica estrictamente dentro del pipeline de CV (riesgo de data leakage).
- Variables PCA anonimizadas limitan la interpretabilidad ante auditorías regulatorias.
- Dataset acotado a 2 días de transacciones europeas de 2013; representatividad geográfica y temporal limitada.
- Ajuste del umbral de decisión puede generar overfitting si se optimiza sobre el mismo conjunto de validación.

Próximos pasos: (1) EDA completo con visualizaciones por clase; (2) implementación de pipeline reproducible con scikit-learn; (3) entrenamiento del baseline y registro de métricas; (4) experimentación con los modelos planificados; (5) optimización del umbral y evaluación final sobre holdout.