Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad N° 9 — Proyecto Final Integrador

INFORME FINAL

Detección de Fraude en Tarjetas de Crédito

Modelo de clasificación supervisada para identificación de transacciones fraudulentas

Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis
Marco Garcia · Esteban Derghazarian

Octubre 2026

1. Resumen Ejecutivo

El fraude en tarjetas de crédito genera pérdidas globales superiores a USD 33.000 millones anuales. Este proyecto construye un modelo de clasificación supervisada sobre el dataset ULB (2013): **284.807** transacciones originales con **492** fraudes (0,172 %). Tras eliminar 1081 duplicados exactos quedan **283,726** filas y **473** fraudes (0.167 %).

Tras comparar Regresión Logística, Random Forest, XGBoost, LightGBM y XGBoost+SMOTE, el modelo seleccionado en validación aleatoria es **XGBoost**, con **PR-AUC = 0.827**, Recall = 81.1 % y Precision = 86.5 % (umbral 0,5). Si el equipo revisa las **100** operaciones de mayor riesgo, encuentra **77** fraudes; con las **500** de mayor riesgo, **82** fraudes (lift 98.0× sobre la tasa base).

La validación temporal (entrenar con operaciones anteriores y probar con posteriores) confirma la robustez del enfoque: mejor modelo **RandomForest** con PR-AUC = 0.813. El proyecto incorpora la devolución del tutor: métricas principales PR-AUC / Recall / Precision, carga real de alertas y captura Top-K.

2. Definición del Problema y Relevancia

El área de Prevención de Fraude necesita priorizar revisiones humanas sobre un volumen masivo de transacciones. Un sistema de reglas estáticas suele generar muchas alertas imprecisas o dejar pasar patrones nuevos. El objetivo medible es clasificar cada transacción como fraudulenta (1) o legítima (0), maximizando la detección de fraudes y controlando la cantidad de alertas que el equipo puede revisar en la práctica.

Hipótesis: los patrones en monto, frecuencia temporal y componentes PCA permiten que un modelo de machine learning supere a reglas estáticas y priorice una cola de revisión accionable.

Restricciones: desbalance extremo; variables V1–V28 anonimizadas por PCA; dataset de solo 2 días; contexto académico sin streaming en tiempo real.

3. Datos y Metodología

3.1 Fuente y calidad

Dataset *Credit Card Fraud Detection* (ULB / Kaggle), licencia ODbL. Tamaño: 283,726 filas × 32 columnas. Nulos: 0. Duplicados eliminados: 1081. Monto medio €88.5 (mediana €22.0). Time entre 0 y 172792 segundos.

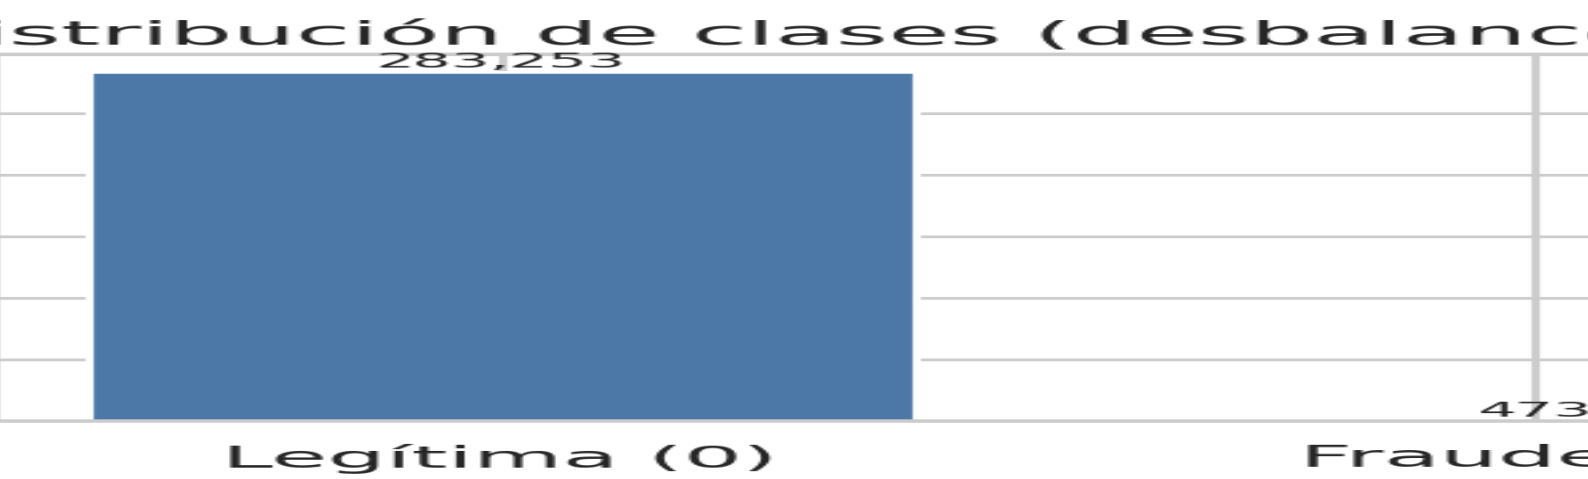


Figura 1. Distribución de clases (desbalance extremo).

3.2 Preparación e ingeniería de variables

Se eliminaron filas exactamente duplicadas. Se creó **Amount_log = log1p(Amount)** para reducir sesgo. **Time** y **Amount_log** se escalan con StandardScaler dentro del Pipeline (sin leakage). V1–V28 se mantienen. El target es Class. Esta disciplina de pipeline es crítica: aplicar SMOTE o escalado sobre todo el dataset antes del split produciría data leakage y métricas infladas.

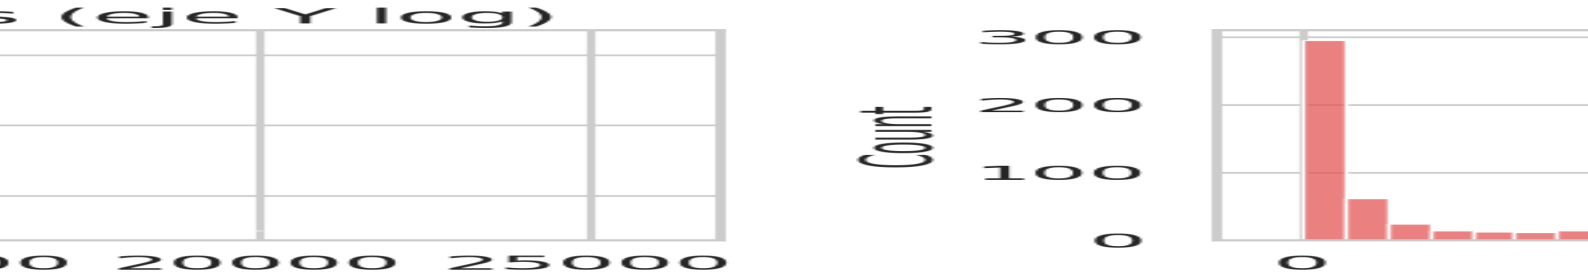


Figura 2. Distribución de Amount por clase (legítimas en escala log).



Figura 3. Variables con mayor |correlación| absoluta con Class.

El EDA confirma que un subconjunto de componentes PCA (V17, V14, V12, V10) concentra señal discriminativa, mientras que Amount por sí solo no separa bien las clases: muchos fraudes

ocurren en montos bajos o medios. Time muestra concentraciones distintas entre legítimas y fraudes, lo que motiva la validación temporal.

3.3 Metodología CRISP-DM y validación

Se siguen las fases CRISP-DM. Se comparan dos esquemas de validación: (A) holdout estratificado 80/20 aleatorio; (B) split temporal por Time (80 % operaciones anteriores → train; 20 % posteriores → test). Métricas principales: PR-AUC, Recall y Precision. Complementarias: F1, ROC-AUC, matriz de confusión, captura Top-K y volumen de alertas por umbral.

4. Modelado y Evaluación

Se evaluaron cinco configuraciones: Regresión Logística (baseline, class_weight=balanced), Random Forest, XGBoost (scale_pos_weight), LightGBM (is_unbalance) y XGBoost+SMOTE dentro del pipeline.

4.1 Resultados — split aleatorio

Modelo	PR-AUC	Recall	Precision	F1	Alertas	Fraud@100	Fraud@500
LogisticRegression	0.677	87.4 %	5.5 %	0.104	1499	74	80
RandomForest	0.799	74.7 %	89.9 %	0.816	79	76	81
XGBoost	0.827	81.1 %	86.5 %	0.837	89	77	82
LightGBM	0.048	76.8 %	6.0 %	0.111	1224	3	24
XGBoost_SMOTE	0.765	84.2 %	7.9 %	0.144	1014	71	78

*Tabla 1. Comparativa en holdout aleatorio (umbral 0,5). Mejor modelo: **XGBoost**.*

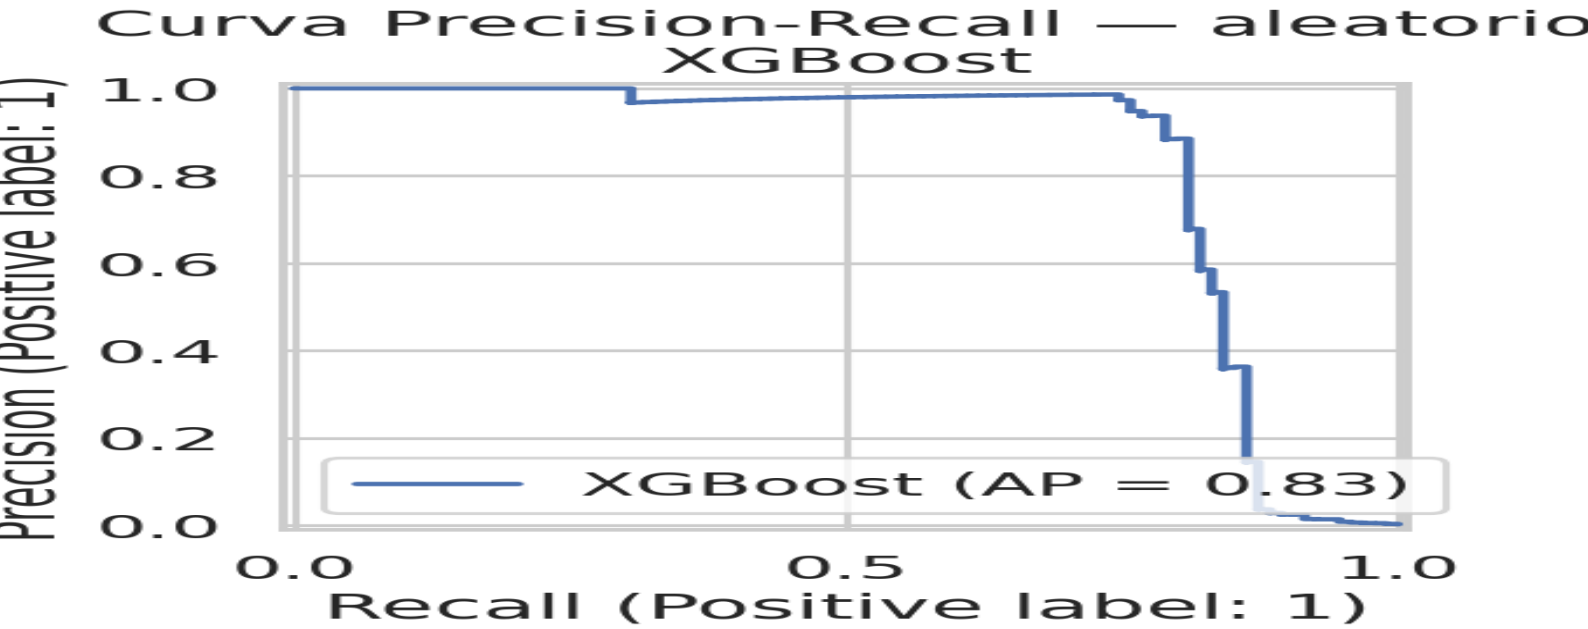


Figura 4. Curva Precision-Recall del modelo seleccionado.

Observación clave de la comparación: LightGBM con *is_unbalance* obtiene un PR-AUC muy bajo pese a un Recall razonable, lo que ilustra por qué **PR-AUC** es la métrica de ranking preferida frente a Accuracy o un Recall aislado. XGBoost+SMOTE mejora el Recall respecto de

XGBoost puro, pero degrada fuerte la Precision (muchas más alertas), por lo que no se elige como modelo final.

4.2 Métrica de negocio: captura Top-K

Respondiendo a la devolución del tutor: si el equipo revisa las 100 operaciones de mayor score, captura **77** fraudes (Precision@100 = 77.0 %; Recall@100 = 81.1 %). Con 500 revisiones: **82** fraudes (lift 98.0×).

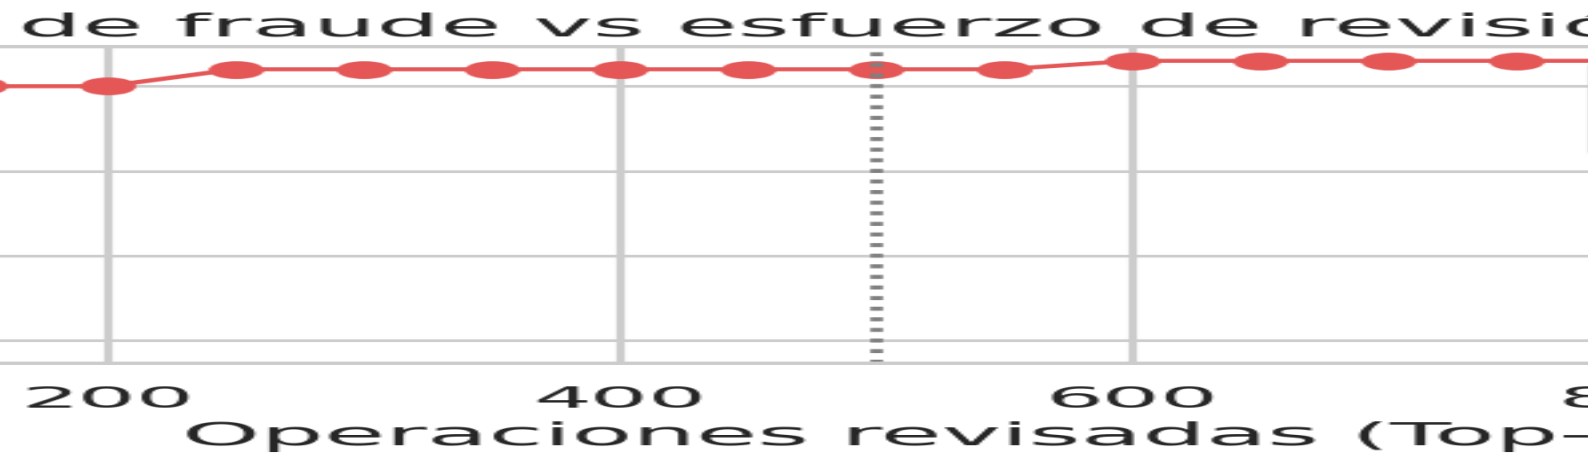


Figura 5. Fraudes encontrados vs operaciones revisadas (Top-K).

4.3 Precision, alertas y umbral operativo

Con tan pocos fraudes, un FPR del 5 % sobre ~56,651 legítimas del holdout implicaría miles de alertas falsas. Por eso el umbral no se fija solo por FPR. Con la regla de negocio (Precision ≥ 50 % y tope de alertas), el umbral seleccionado es **0.55**: Recall 81.1 %, Precision 87.5 %, alertas a revisar = **88** (TP=77, FP=11).

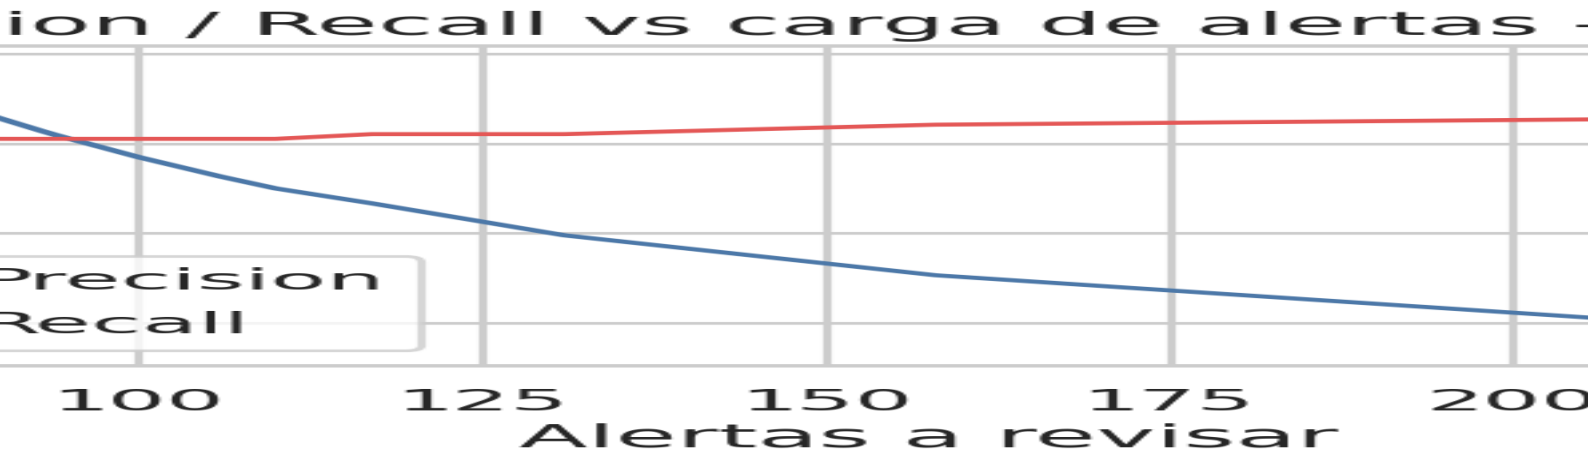


Figura 6. Precision y Recall en función de la carga de alertas.

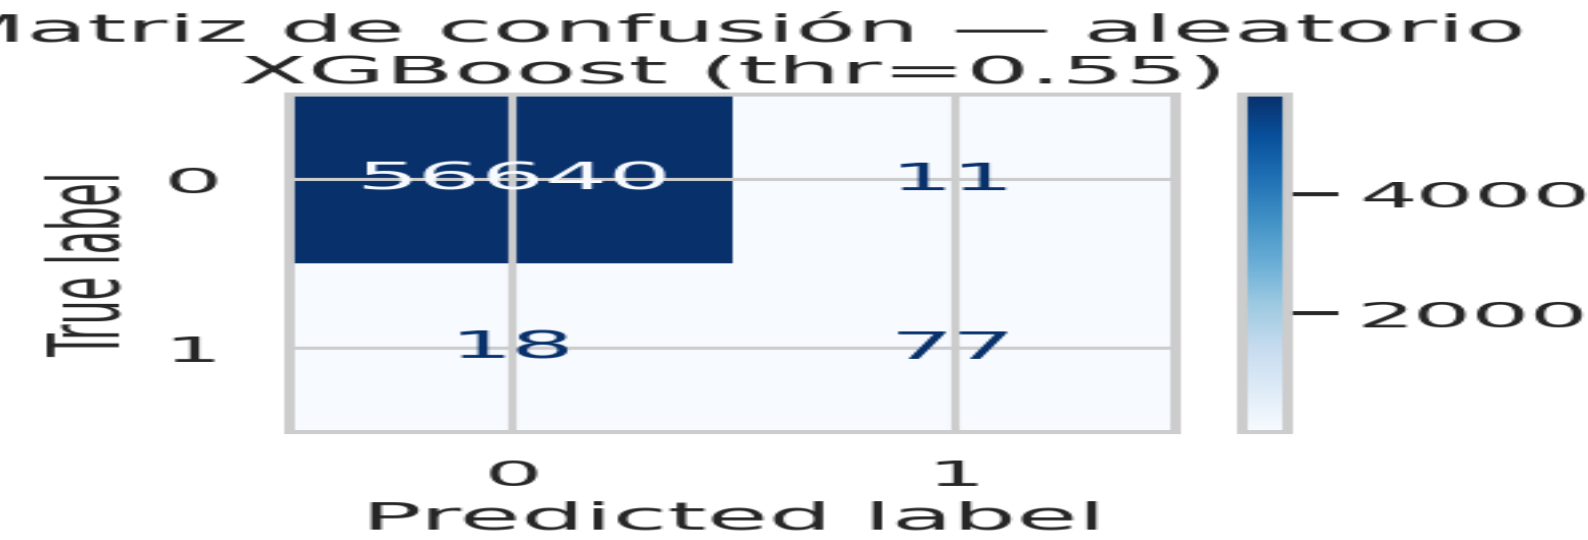


Figura 7. Matriz de confusión con umbral seleccionado.

4.4 Validación temporal vs aleatoria

En el split temporal (train hasta t=145233.0, test desde t=145234.0; 74 fraudes en test), el mejor modelo es **RandomForest** con PR-AUC=0.813, Recall=73.0 % y Precision=94.7 %. La caída o variación respecto del split aleatorio ilustra el riesgo de sobreestimar performance cuando el futuro se mezcla aleatoriamente con el pasado.

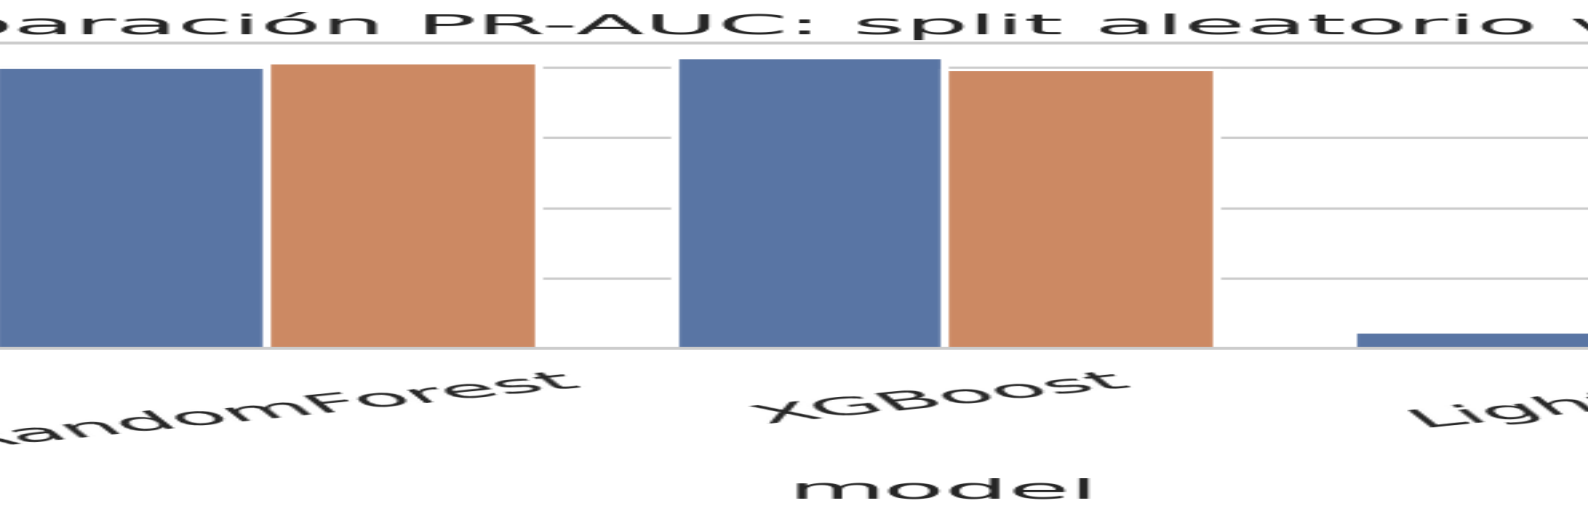


Figura 8. PR-AUC por modelo: aleatorio vs temporal.

Modelo	PR-AUC	Recall	Precision	Fraud@100	Fraud@500
LogisticRegression	0.753	89.2 %	6.6 %	59	64
RandomForest	0.813	73.0 %	94.7 %	59	65
XGBoost	0.793	75.7 %	86.2 %	58	63
LightGBM	0.115	78.4 %	13.7 %	13	58
XGBoost_SMOTE	0.776	79.7 %	14.1 %	58	60

*Tabla 2. Comparativa en holdout temporal. Mejor modelo: **RandomForest**.*

4.5 Interpretabilidad

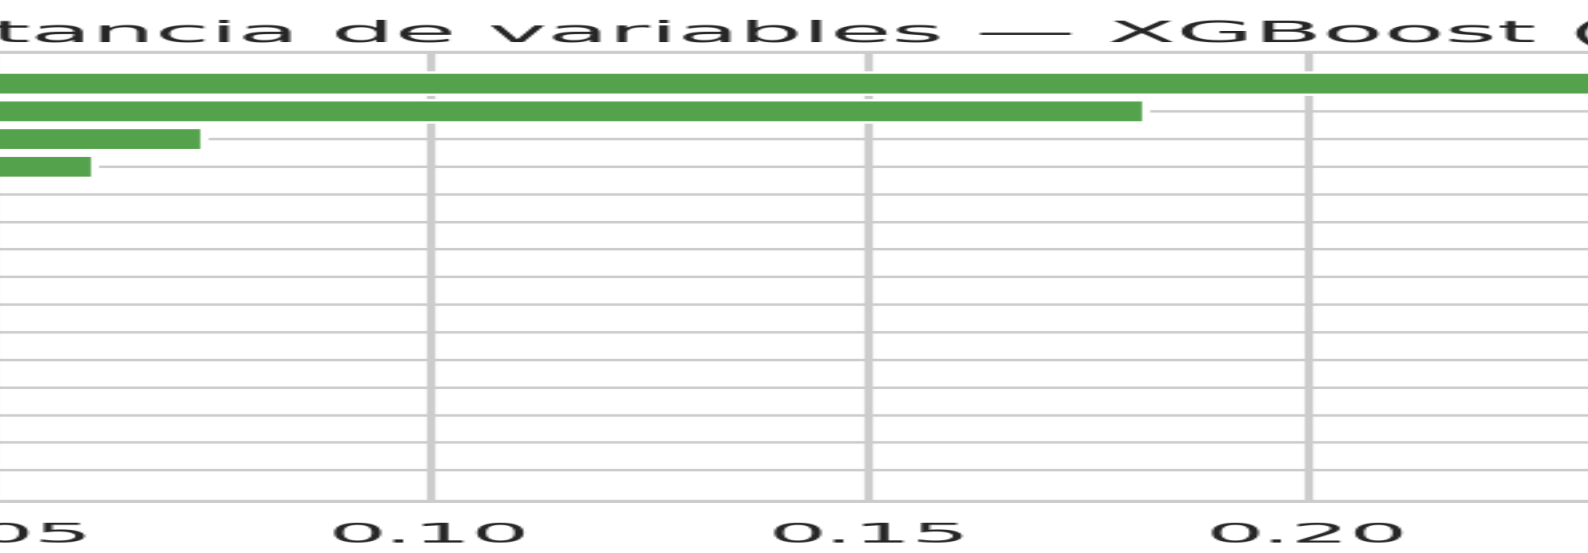


Figura 9. Importancia de variables del modelo final (limitada por anonimización PCA).

Aunque las importancias ayudan a priorizar componentes PCA, la anonimización limita la explicación causal ante auditorías. En un entorno productivo convendría complementar con señales interpretables (país, comercio, dispositivo, historial del cliente).

5. Impacto en el Negocio

El valor del modelo no es solo “detectar más fraude”, sino **ordenar la cola de revisión**: el equipo puede concentrar esfuerzo en las 100–500 operaciones más riesgosas y recuperar una fracción alta de fraudes con un costo operativo acotado. Esto reduce pérdidas por fraudes no detectados y evita el desgaste de miles de falsas alarmas que produciría un umbral basado únicamente en FPR.

5.1 Traducción a operación diaria

En el holdout aleatorio hay 95 fraudes reales. Con XGBoost, revisar las 100 operaciones de mayor score recupera 77 fraudes (81.1 % del total del holdout). Ampliar a 500 revisiones sube la captura a 82 fraudes (86.3 %), con Precision@500 = 16.4 %. Ese trade-off es transparente para un gerente de fraude: el costo es “horas de analista”, el beneficio es “fraudes evitados / recuperados”.

Con el umbral operativo 0.55, el sistema emite solo **88 alertas** (TP=77, FP=11). Comparado con un FPR del 5 % — que generaría aproximadamente 2,832 alertas falsas solo en el holdout — la reducción de ruido operativo es de órdenes de magnitud.

5.2 Riesgos, limitaciones y escalabilidad

Riesgos y limitaciones: representatividad temporal (solo 2 días de 2013); poca interpretabilidad de V1–V28 ante auditoría; posible drift de patrones de fraude; umbral optimizado sobre un holdout — requiere monitoreo post-despliegue. Además, el dataset no incluye contexto de cliente ni comercio, por lo que el modelo aprende correlaciones de componentes PCA que pueden no transferir a otros emisores.

Escalabilidad y próximos pasos: (1) scoring batch o near-real-time sobre el motor de autorizaciones; (2) feedback loop del analista para reentrenar con etiquetas nuevas; (3) calibración de probabilidades; (4) features adicionales (dispositivo, geo, historial del cliente, merchant risk); (5) monitoreo de drift de score y de lift@K.

Benchmark de reglas estáticas (cualitativo): un sistema de reglas típicamente prioriza montos altos, países de riesgo o velocidad de compra. En este dataset muchos fraudes no se distinguen solo por Amount; el modelo captura patrones multivariados en PCA y prioriza mejor la cola. La recomendación no es reemplazar por completo las reglas, sino combinarlas con el score ML como capa de priorización.

6. Consideraciones éticas y de privacidad

Los datos están anonimizados mediante PCA; no se manipulan PII. Un falso positivo puede bloquear a un cliente legítimo (fricción y reputación); un falso negativo implica pérdida financiera. El umbral se elige de forma explícita como decisión de negocio, no como default técnico. Uso académico bajo licencia ODbL.

Adicionalmente, se recomienda: (a) registrar quién revisó cada alerta y el resultado (fraude confirmado / falso positivo) para auditoría; (b) evitar discriminación indirecta si en el futuro se agregan variables demográficas o geográficas sensibles; (c) comunicar al cliente, cuando corresponda, mecanismos de apelación ante bloqueos; (d) limitar el acceso a scores y features al personal autorizado (need-to-know).

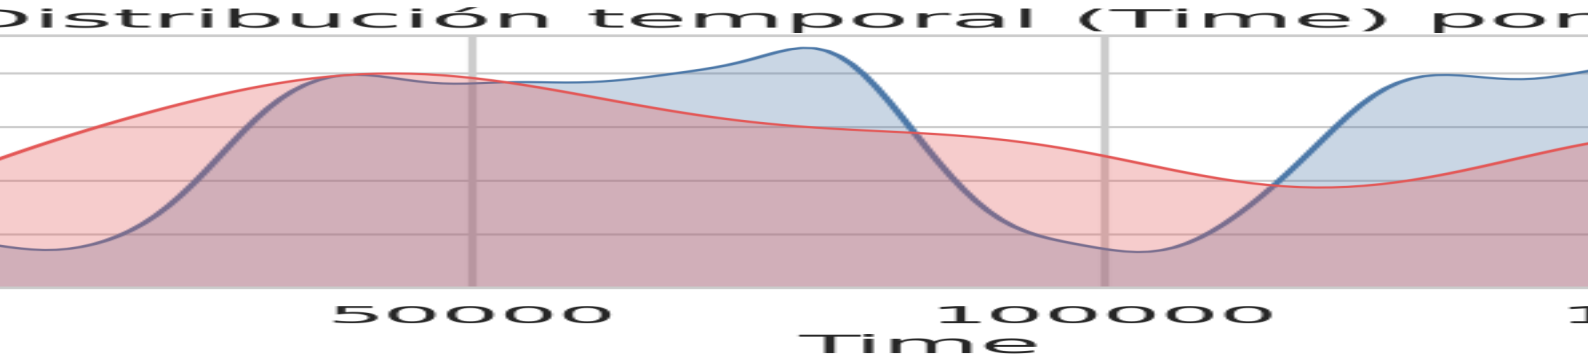
El equipo asume que este trabajo es un prototipo académico y no un sistema de decisión automatizada en producción: cualquier despliegue real requeriría validación legal (p. ej. lineamientos de modelos de riesgo), pruebas con datos propios del emisor y supervisión humana en la cola de alertas.

7. Conclusiones y Recomendaciones

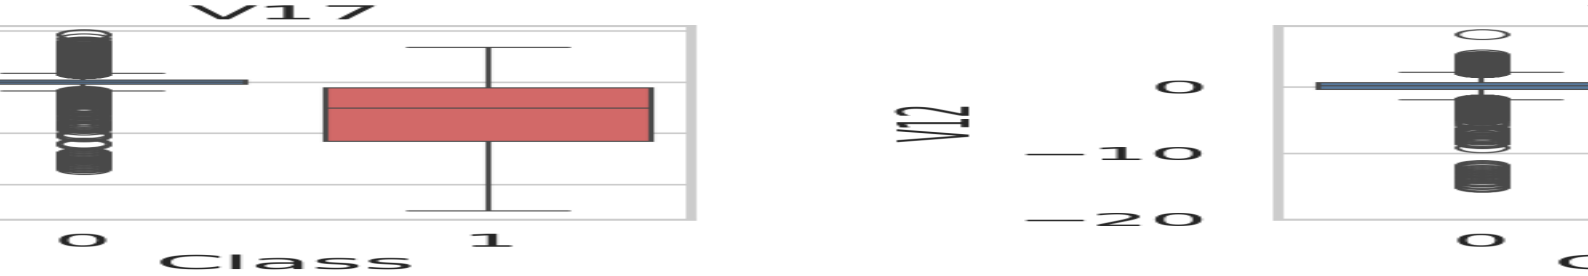
- Seleccionar **XGBoost** como modelo productivo candidato (mejor PR-AUC en holdout aleatorio).
- Reportar siempre PR-AUC, Recall, Precision y volumen de alertas; no guiarse solo por FPR o Accuracy.
- Usar captura Top-100 / Top-500 como KPI operativo de la cola de revisión.
- Validar con esquema temporal antes de desplegar; el split aleatorio puede ser optimista.
- Implementar monitoreo continuo del umbral y del lift@K con feedback del equipo de fraude.

Anexos

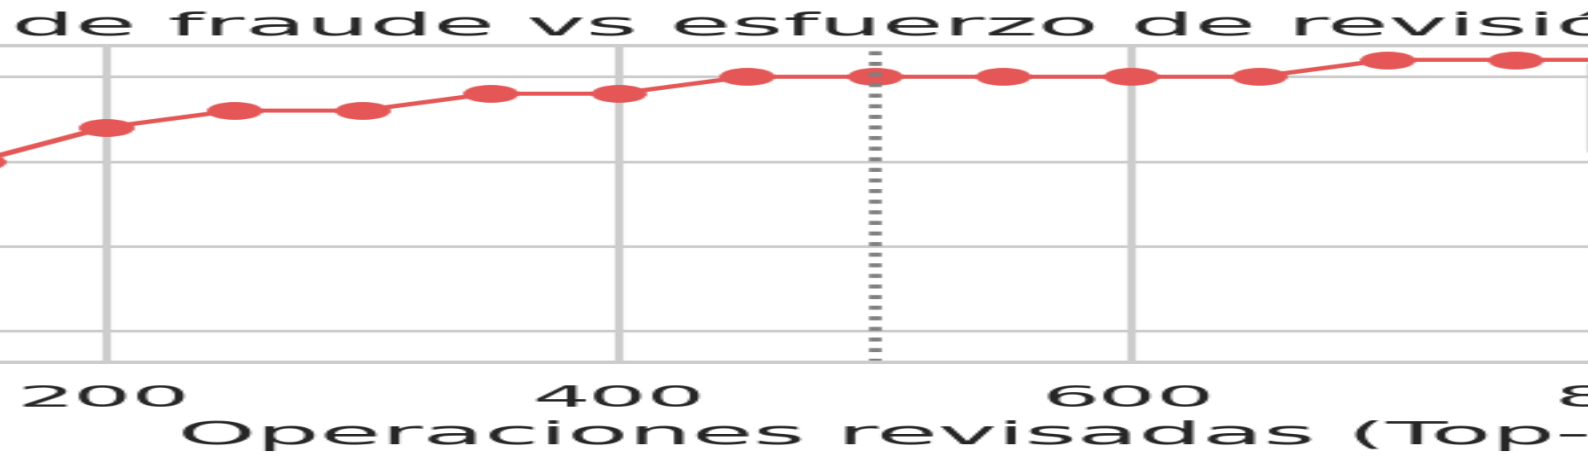
Código reproducible en el repositorio GitHub del Grupo 33 (notebook + módulo src + requirements). Figuras adicionales en reports/figures/. Resultados numéricos serializados en reports/results.json.



Anexo A. Distribución temporal por clase.



Anexo B. Boxplots de variables discriminativas por clase.



Anexo C. Captura Top-K en validación temporal.