INFORME FINAL

Detección de fraude en tarjetas de crédito: priorización de la cola de revisión

Diplomado en Ciencia de Datos y Análisis Avanzado

Unidad N.º 9 — Proyecto Final Integrador

Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis
Marco Garcia · Esteban Derghazarian

Octubre 2026

Índice

1. Resumen ejecutivo — 2. Definición del problema y relevancia — 3. Datos y metodología — 4. Modelado y evaluación — 5. Interpretación del modelo — 6. Impacto en el negocio, riesgos y ética — 7. Conclusiones y recomendaciones — Anexos

1. Resumen ejecutivo

Problema. Un emisor de tarjetas (audiencia: Prevención de Fraude) debe decidir qué operaciones revisar a mano. El dataset ULB tiene **284.807** transacciones y solo **492** fraudes (0,172 %). Con tan pocos positivos, un FPR del 5 % sobre las ~56,651 legítimas del holdout produciría unas **2,832 alertas falsas**. No alcanza con controlar FPR: hay que mirar Precision y cuántas operaciones revisaría el equipo.

Solución. Un modelo candidato **XGBoost** que ordena las transacciones por score de riesgo. El producto no es un "sí/no" rígido, sino una cola de revisión: el equipo mira primero las operaciones de mayor riesgo. La selección se basó en PR-AUC, Recall y Precision, y se contrastó un split aleatorio estratificado con una validación temporal por *Time*.

Indicador (holdout)	Azar / sin modelo	XGBoost aleatorio	RandomForest temporal
PR-AUC	≈ 0,002 (tasa base)	0,827	0,813
Recall (umbral 0,5)	—	81.1 %	73.0 %
Precision (umbral 0,5)	—	86.5 %	94.7 %
Fraudes en Top-100	≈ 1	77	59
Fraudes en Top-500	≈ 1	82	65
Alertas con umbral operativo	miles (si FPR=5 %)	88	ver §4.4

Tabla 1. Lectura de negocio: captura de fraude con el mismo esfuerzo de revisión.

Resultado. En holdout aleatorio (95 fraudes en 56,746 operaciones), XGBoost alcanza PR-AUC 0,827, Recall 81.1 % y Precision 86.5 %. Si el equipo revisa las 100 operaciones de mayor riesgo encuentra **77** fraudes (Precision@100 = 77.0 %); con 500 revisiones, **82** fraudes (lift 98,0×). Con umbral 0.55 emite solo **88 alertas** (77 TP / 11 FP).

Límite y recomendación. En validación temporal el mejor modelo es RandomForest (PR-AUC 0,813; Top-100 = 59 fraudes). La señal se sostiene, pero el split aleatorio es algo más optimista. Se recomienda usar el score para priorizar la cola, fijar el umbral según la capacidad del equipo y revalidar en ventanas temporales nuevas antes de un despliegue real.

2. Definición del problema y relevancia

La pregunta de negocio no es "¿esta transacción es fraude con certeza?", sino **a qué operaciones asignar primero un cupo limitado de revisión humana**. El producto es un ranking. La relevancia es directa: cada fraude no detectado es pérdida financiera y cada falsa alarma consume analista y puede bloquear a un cliente legítimo.

Objetivo medible (fijado en la pre-entrega y ajustado por la devolución): maximizar Recall de fraude manteniendo Precision y un volumen de alertas operable. Métricas

principales: PR-AUC, Recall y Precision. Métrica de negocio: captura en Top-100 y Top-500. Benchmark: un orden aleatorio captura, en el holdout, unos 1 fraudes entre 100 revisiones; el modelo debe multiplicar ese lift.

Situación	Lectura estadística	Costo de negocio
Alerta sobre operación legítima	Falso positivo	Horas de analista + fricción al cliente
Fraude que no entra a la cola	Falso negativo	Pérdida del monto y daño reputacional
FPR ≤ 5 % como única traba	Miles de FP con 0,17 % de prevalencia	El equipo no puede revisar esa cola

Tabla 2. Costos del error. El umbral es una decisión de capacidad, no un default técnico.

Hipótesis. H1: los componentes PCA (V1–V28) concentran señal discriminativa. H2: el monto, transformado a escala logarítmica, aporta menos que las V* pero ayuda a calibrar riesgo. H3: como existe *Time*, un split aleatorio puede sobreestimar el desempeño; entrenar con operaciones anteriores y probar con posteriores es la prueba más realista.

3. Datos y metodología

3.1 Fuente y calidad

Fuente. Credit Card Fraud Detection, ULB Machine Learning Group / Kaggle (Dal Pozzolo, Caelen, Johnson y Bontempi, 2015). Licencia ODbL v1.0. Transacciones de titulares europeos en septiembre de 2013 (dos días). Archivo original: 284.807 filas × 31 columnas. Tasa de fraude: 0,172 %. El CSV se descarga de un mirror público y se cachea en *data/creditcard.csv*; el esquema se valida al cargar (Time, V1–V28, Amount, Class).

Hallazgo de calidad	Decisión y motivo
0 nulos	Ninguna imputación.
1081 duplicados exactos	Eliminados; quedan 283,726 filas y 473 fraudes.
Amount sesgado (media €88; mediana €22)	Amount_log = log1p(Amount); el crudo no entra al modelo.
V1–V28 ya son PCA anonimizado	Se usan sin reescalar; limitan interpretación causal.
Time en [0 ; 172.792] s	Se escala en el Pipeline y se usa para el split temporal.
Desbalance 0,17 %	class_weight / scale_pos_weight / SMOTE dentro del Pipeline.

Tabla 3. Decisiones de calidad registradas (equivalente a un data log).

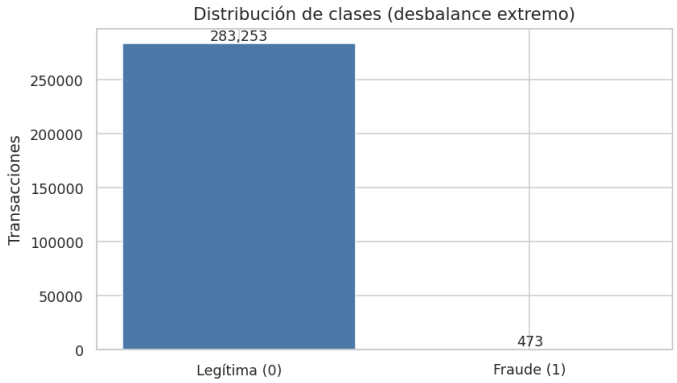


Figura 1. Distribución de clases tras la limpieza: el positivo es raro.

3.2 Conclusiones del EDA

Las variables con mayor |correlación| con Class son V17 (0,31), V14 (0,29) y V12 (0,25). Amount por sí solo no separa bien: hay fraudes en montos bajos y medios. Time muestra concentraciones distintas por clase, lo que respalda H3. Accuracy o ROC-AUC aislados son engañosos: un clasificador trivial “todo legítimo” tendría Accuracy 99,83 % y no detectaría ningún fraude.

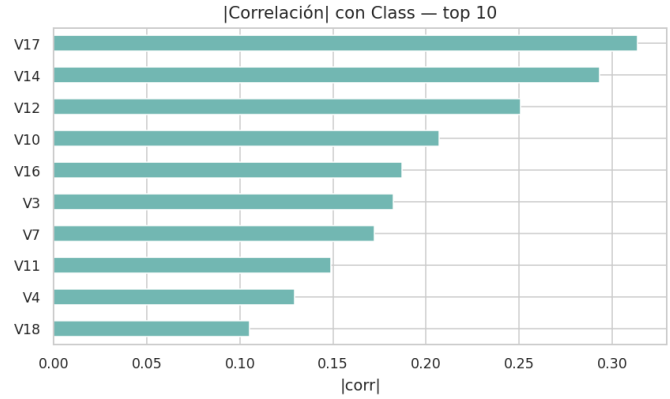


Figura 2. |Correlación| absoluta con Class (top 10). Respaldo descriptivo de H1.

3.3 Preparación y CRISP-DM

Metodología. Se siguió CRISP-DM: negocio (sección 2), comprensión y preparación de datos (esta sección), modelado y evaluación (sección 4) y traducción a una decisión (secciones 5–6). Todas las transformaciones viven en un Pipeline de scikit-learn / imbalanced-learn: StandardScaler sobre Time y Amount_log; V1–V28 pasan sin cambios; SMOTE, cuando se usa, queda **dentro** del pipeline para no filtrar información del test. random_state=42.

Diseño de validación	Pregunta que responde
Holdout estratificado 80/20 (una sola vez)	¿Cuánto rinde en una mezcla i.i.d. de las 48 h?
Split temporal por Time (80 % anterior → 20 % posterior)	¿Generaliza hacia operaciones futuras?
Comparación de cinco algoritmos en ambos esquemas	¿Qué modelo discrimina mejor (PR-AUC) sin saturar alertas?

Tabla 4. Dos diseños de validación, como pidió la devolución del tutor.

4. Modelado y evaluación

4.1 Algoritmos y regla de selección

Se compararon cinco configuraciones, todas con manejo explícito del desbalance: Regresión Logística (baseline, class_weight=balanced), Random Forest (class_weight), XGBoost (scale_pos_weight), LightGBM (is_unbalance) y XGBoost+SMOTE dentro del pipeline. **Regla de selección definida antes de elegir el umbral:** gana el mayor PR-AUC en el holdout aleatorio; el desempate lo dan Recall, Precision y el volumen de alertas. El split temporal no cambia la regla: sirve para medir robustez y avisar si el candidato se degrada.

Modelo	PR-AUC	Recall	Precision	F1	Alertas	Fraud@100	Fraud@500
LogisticRegression	0,677	87.4 %	5.5 %	0,104	1499	74	80
RandomForest	0,799	74.7 %	89.9 %	0,816	79	76	81
XGBoost *	0,827	81.1 %	86.5 %	0,837	89	77	82
LightGBM	0,048	76.8 %	6.0 %	0,111	1224	3	24
XGBoost_SMOTE	0,765	84.2 %	7.9 %	0,144	1014	71	78

*Tabla 5. Holdout aleatorio, umbral 0,5. *Candidato: XGBoost. Test: 56,746 filas / 95 fraudes.*

LightGBM obtiene Recall razonable (76.8 %) pero PR-AUC 0,048: el ranking es pobre y Top-100 apenas captura 3 fraudes. XGBoost+SMOTE sube Recall a 84.2 % pero cae la Precision a 7.9 % (1014 alertas). La logística detecta mucho (Recall alto) a costa de 1.499 alertas. Random Forest es preciso pero recupera menos fraude. XGBoost gana el equilibrio que pide el negocio: PR-AUC 0,827, 89 alertas y 77 fraudes en Top-100.

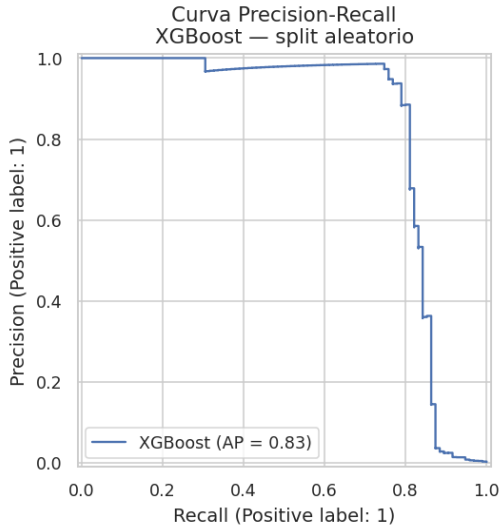


Figura 3. Curva Precision-Recall de XGBoost en el holdout aleatorio (AP = 0,83).

4.2 Métrica de negocio: captura Top-K

Si el equipo revisa las 100 operaciones de mayor score encuentra **77** de los 95 fraudes del holdout (Recall@100 = 81.1 %; Precision@100 = 77.0 %). Ampliar a 500 revisiones

suma solo 5 fraudes más (lift 98,0× sobre la tasa base de 0.167 %). La curva se aplana: el valor está en el tope del ranking, no en revisar más y más.

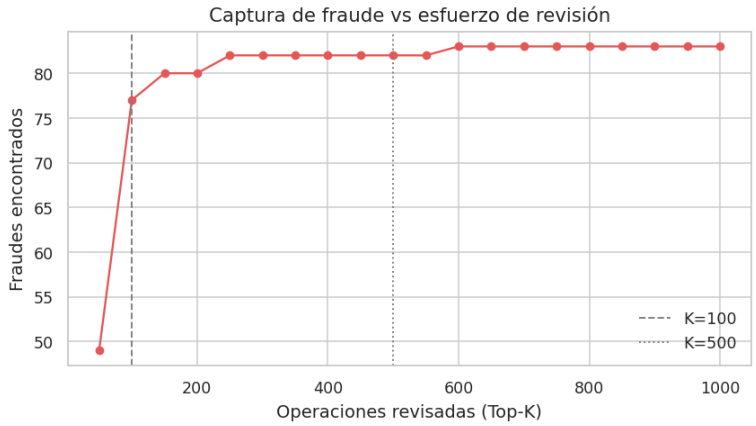


Figura 4. Fraudes encontrados vs operaciones revisadas (Top-K). Líneas en K=100 y K=500.

4.3 Umbral operativo y carga de revisión

Un FPR del 5 % sobre 56,651 legítimas implica ~2,832 falsos positivos en un solo holdout. Por eso el umbral no se fija por FPR. Regla usada: Precision ≥ 50 % y tope de alertas cercano a 100–500 (capacidad de un turno). El umbral 0.55 deja **88 alertas**, Recall 81.1 % y Precision 87.5 % (TP=77, FP=11, FN=18). Esa es la carga real que tendría que revisar el equipo.

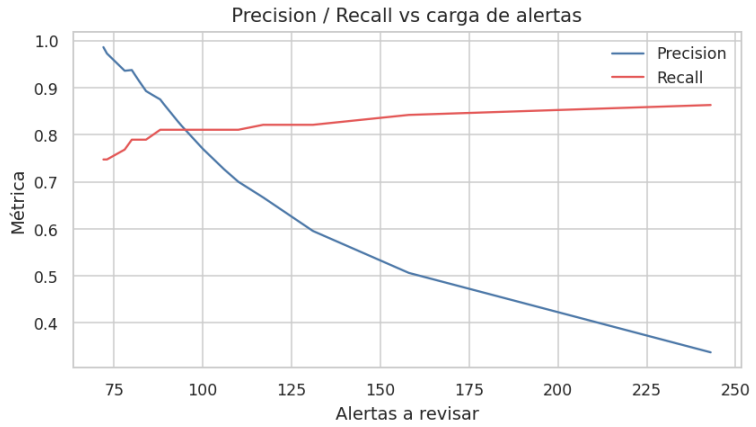


Figura 5. Precision y Recall en función del número de alertas. El recorte operativo está a la izquierda.

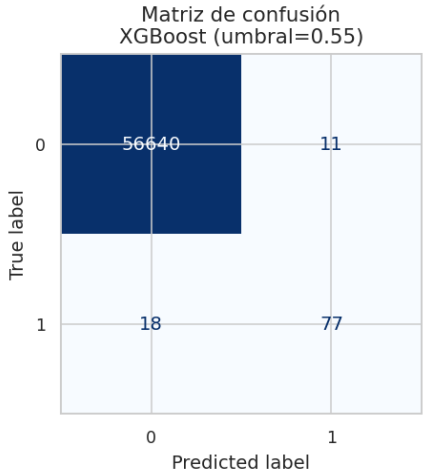


Figura 6. Matriz de confusión de XGBoost con umbral 0.55.

4.4 Validación temporal versus aleatoria

Se ordenó por Time y se entrenó con las primeras 226,980 operaciones (399 fraudes; Time ≤ 145233 s) y se evaluó con las 56,746 posteriores (74 fraudes). Es el diseño que pide la devolución y el más cercano a producción: el modelo no ve el "futuro" de las 48 horas.

Modelo	PR-AUC	Recall	Precision	Fraud@100	Fraud@500
LogisticRegression	0,753	89.2 %	6.6 %	59	64
RandomForest *	0,813	73.0 %	94.7 %	59	65
XGBoost	0,793	75.7 %	86.2 %	58	63
LightGBM	0,115	78.4 %	13.7 %	13	58
XGBoost_SMOTE	0,776	79.7 %	14.1 %	58	60

*Tabla 6. Holdout temporal. *Mejor PR-AUC: RandomForest. Test: 74 fraudes.*

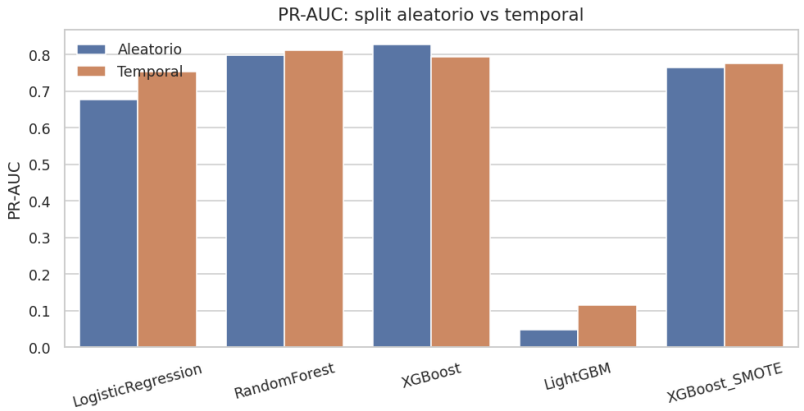


Figura 7. PR-AUC por modelo en ambos esquemas. LightGBM se cae en ranking; el resto sostiene la señal.

Lectura. XGBoost sigue siendo competitivo en temporal (PR-AUC 0,793), pero RandomForest lo supera levemente y con Precision 94.7 %. La captura Top-100 baja de 77 a 59 fraudes, en parte porque el test temporal tiene menos positivos (74 vs 95). H3 queda respaldada: el aleatorio no miente, pero es el techo; el temporal es el piso más honesto para decidir un piloto.

5. Interpretación del modelo

Sobre XGBoost se leyeron importancias de split (no son causalidad ni SHAP). Las V* más usadas coinciden con el EDA (V14, V17, V12 y vecinas). Time y Amount_log aportan, pero no lideran. Como las V* son PCA, el negocio no puede traducir “sube V14” a una regla de comercio o país: el modelo prioriza, no explica el fraude ante un auditor. En un emisor real habría que complementar con features interpretables (MCC, dispositivo, geo, historial).

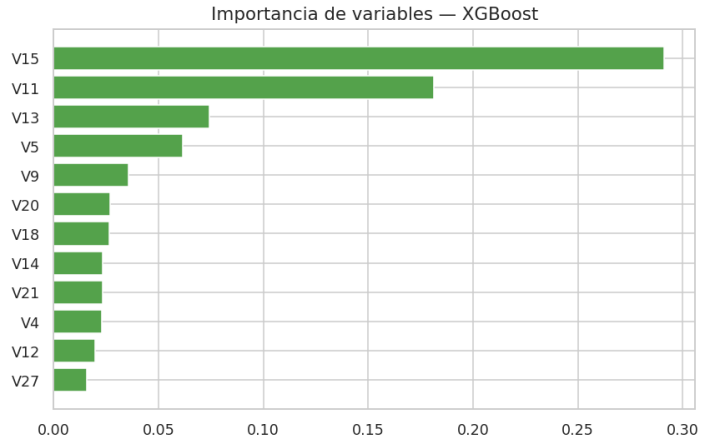


Figura 8. Importancia de variables de XGBoost (split aleatorio). Lectura descriptiva, no causal.

El score se usa para **ordenar**. Un valor 0,80 no se interpreta aquí como “probabilidad calibrada del 80 %”: no se reporta curva de calibración. Para un umbral de corte (sección 4.3) alcanza con el ranking y la matriz de confusión. Si el área quisiera comunicar “1 de cada 5 alertas es fraude”, habría que calibrar (Platt / isotónica) sobre un conjunto aparte.

6. Impacto en el negocio, riesgos y ética

Sin ranking, capturar ~81 % de los fraudes del holdout exigiría revisar una fracción enorme de la cartera o convivir con miles de alertas. Con el modelo, ese Recall se obtiene revisando 88 operaciones, o 77 fraudes con solo 100 revisiones. El ahorro no es un monto de 2013 “real”: es **capacidad de analista liberada** y fraudes que entran a la cola a tiempo. Un FPR del 5 % costaría ~2,832 revisiones falsas; el umbral elegido cuesta 11 FP.

Escenario de revisión	Operaciones a mirar	Fraudes hallados	Precision
Azar (100 casos)	100	≈ 1	≈ tasa base
Modelo Top-100	100	77	77.0 %
Modelo Top-500	500	82	16.4 %
Umbral 0.55	88	77	87.5 %
Regla FPR = 5 %	~2,832+	alto Recall, baja Precision	muy baja

Tabla 7. El valor está en ordenar la cola, no en umbrales holgados de FPR.

Riesgo	Mitigación
Dataset de solo 2 días (2013), Europa	Tratar el caso como prueba de método; reentrenar con datos propios del emisor.
Drift de patrones de fraude	Monitorear PR-AUC, Precision y captura@K por día; reentrenar.
PCA poco explicable ante auditoría	Usar el score para priorizar; complementar con reglas y features nativas.
Falso positivo = bloqueo de cliente	Umbral según capacidad; canal de apelación; no automatizar el rechazo final.
Fuga si SMOTE o scaler ven el test	Pipeline único; holdout separado antes de cualquier ajuste.
Privacidad	Datos ya anonimizados; minimización; acceso need-to-know al score.

Tabla 8. Riesgos y mitigaciones. El prototipo no autoriza un despliegue automático.

Ética. No hay PII. El umbral es una decisión explícita de negocio (Precision y cupo), no un default de 0,5. Un falso negativo pierde dinero; un falso positivo daña al cliente: por eso se reportan ambos y el volumen absoluto de alertas. Uso académico bajo ODbL. Cualquier producción requeriría supervisión humana, registro de cada alerta y revisión legal del modelo de riesgo.

7. Conclusiones y recomendaciones

- El problema se formuló como **priorización bajo capacidad limitada**. PR-AUC, Recall, Precision y captura Top-K reflejan esa decisión mejor que Accuracy o un FPR suelto.
- **XGBoost** es el candidato en distribución mezclada: PR-AUC 0,827, Recall 81.1 %, Precision 86.5 %; Top-100 = 77 fraudes; umbral 0.55 → 88 alertas.
- H1 tiene respaldo descriptivo (V17, V14, V12). H3 también: en temporal gana RandomForest (PR-AUC 0,813) y la captura Top-100 baja a 59. El aleatorio es techo; el temporal es la prueba de piloto.
- SMOTE y LightGBM (is_unbalance) no se eligen: mejoran o sostienen Recall pero destruyen Precision o PR-AUC.
- Recomendación: **no desplegar a ciegas**. Usar el score para ordenar la cola, fijar el umbral según el turno de analistas, reentrenar con datos actuales del emisor y medir captura@100/@500 y drift en una ventana temporal nueva.

Código. Repositorio del Grupo 33: notebook *notebooks/TP_Final_Deteccion_Fraude.ipynb*, módulo *src/*, *requirements.txt* y *reports/results.json*. El pipeline se reproduce con *python -m src.run_pipeline*.

Anexos

Anexo A. Trazabilidad con la consigna, la pre-entrega y la devolución

Peso	Criterio	Dónde está en este informe
20 %	Problema y negocio	§1–2: ranking, costos FP/FN, KPI Top-K
20 %	Datos y metodología	§3: calidad, EDA, Pipeline, dos validaciones
15 %	Selección del modelo	§4.1 y Tablas 5–6
15 %	Calidad de métricas	PR-AUC, Recall, Precision, Top-K, alertas
15 %	Interpretación y valor	§5–6: importancias y carga de revisión
5 %	Ética y privacidad	§6 y Tabla 8
10 %	Claridad	Resumen no técnico, figuras y recomendación

Tabla A1. Cobertura de los criterios de evaluación.

Pedido de la devolución	Estado
PR-AUC, Recall y Precision como métricas principales	Tablas 1, 5 y 6; no se decide por FPR.
Cuántas operaciones revisaría el equipo	§4.3: 88 alertas vs ~2.832 si FPR=5 %.
Captura si se revisan Top-100 / Top-500	Figura 4 y Tabla 7.
Comparar split aleatorio vs temporal por Time	§4.4, Figura 7, Tabla 6.

Tabla A2. Cierre de la devolución del tutor.

Anexo B. Figuras complementarias de EDA

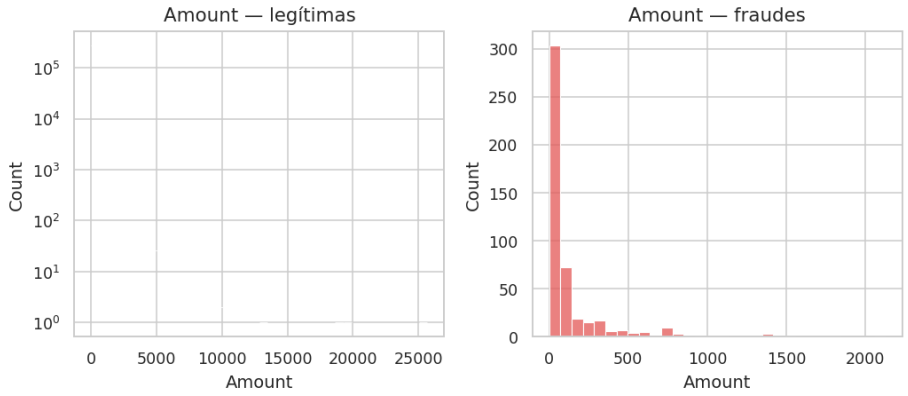


Figura B1. Amount por clase. Las legítimas se muestran con eje Y en log.

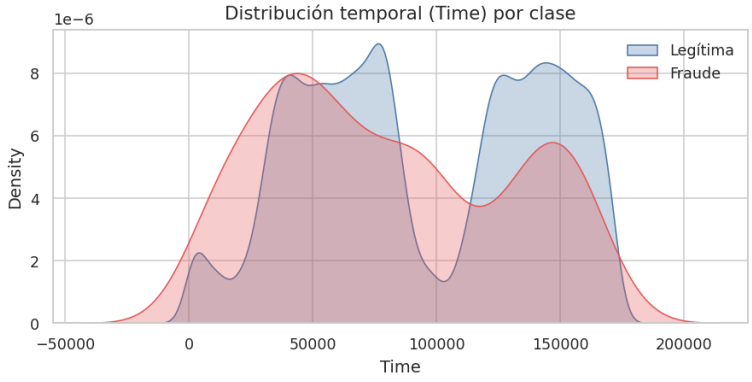


Figura B2. Densidad de Time por clase: hay estructura temporal (H3).

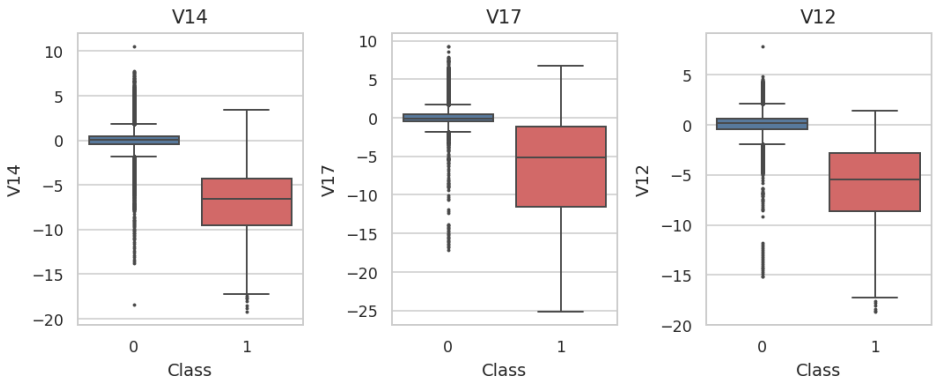


Figura B3. Boxplots de V14, V17 y V12 por clase.

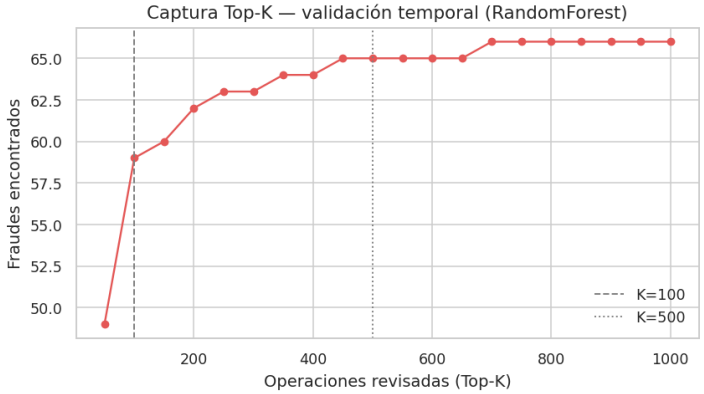


Figura B4. Captura Top-K en el split temporal (RandomForest).

Anexo C. Reproducibilidad y fuentes

Dal Pozzolo, A., Caelen, O., Johnson, R. A. y Bontempi, G. (2015). *Calibrating Probability with Undersampling for Unbalanced Classification*. IEEE CIDM. Dataset: Credit Card Fraud Detection (ULB). Licencia ODbL v1.0. Chapman, P. et al. (2000). *CRISP-DM 1.0*. Repositorio del equipo: https://github.com/SolKidonakis/TP_Final_DataScience