PROYECTO FINAL INTEGRADOR

Detección de Fraude en Tarjetas de Crédito

Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis

Marco Garcia · Esteban Derghazarian

Octubre 2026

Agenda

1. Problema de negocio y objetivo
2. Datos y desbalance extremo
3. Metodología CRISP-DM
4. Modelos y métricas principales (PR-AUC, Recall, Precision)
5. Métrica de negocio: captura Top-100 / Top-500
6. Validación temporal vs aleatoria
7. Impacto, riesgos y recomendaciones

El problema: fraude con pocos casos y muchas operaciones

Pérdidas globales > USD 33.000 M / año por fraude en tarjetas.

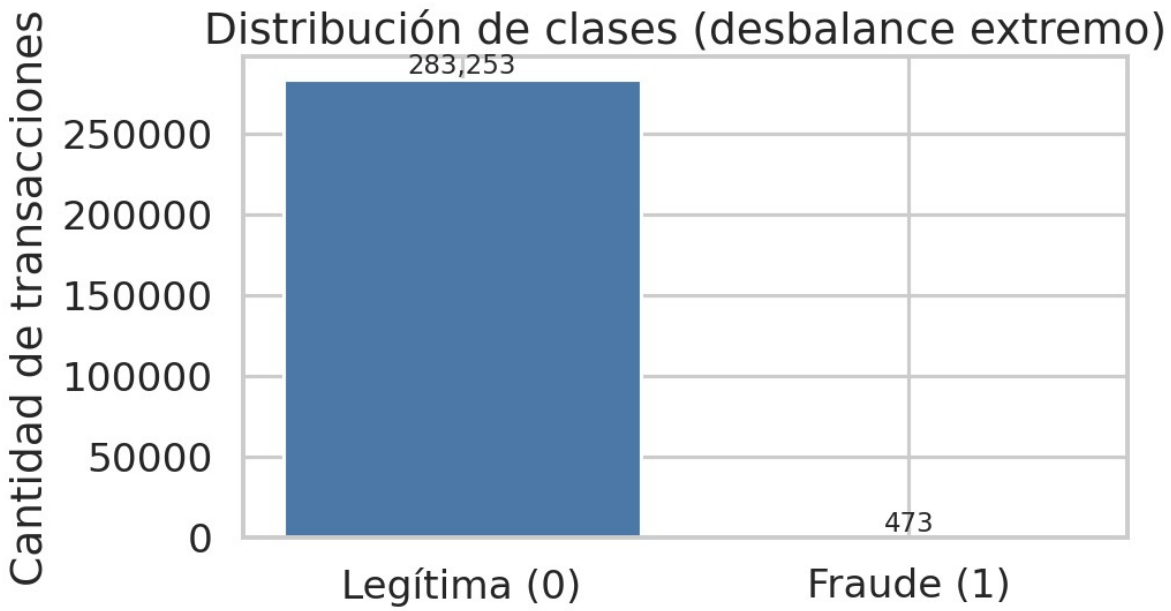
Dataset ULB: 283,726 transacciones · solo 473 fraudes (0.167%).

Audiencia: Prevención de Fraude / Riesgo Crediticio.

Objetivo: maximizar detección SIN saturar al equipo con falsas alertas.

Hipótesis: ML supera reglas estáticas priorizando una cola de revisión accionable.

Datos: desbalance extremo



473 fraudes vs 283,253 legítimas.

Sin nulos; duplicados eliminados.

V1–V28 = PCA anonimizado.

Amount sesgado → log1p.

Time habilita validación temporal.

Accuracy engaña → usamos PR-AUC.

Metodología CRISP-DM

Preparación en Pipeline: StandardScaler(Time, Amount_log) sin leakage.

Modelos: Logistic Regression · Random Forest · XGBoost · LightGBM · XGBoost+SMOTE.

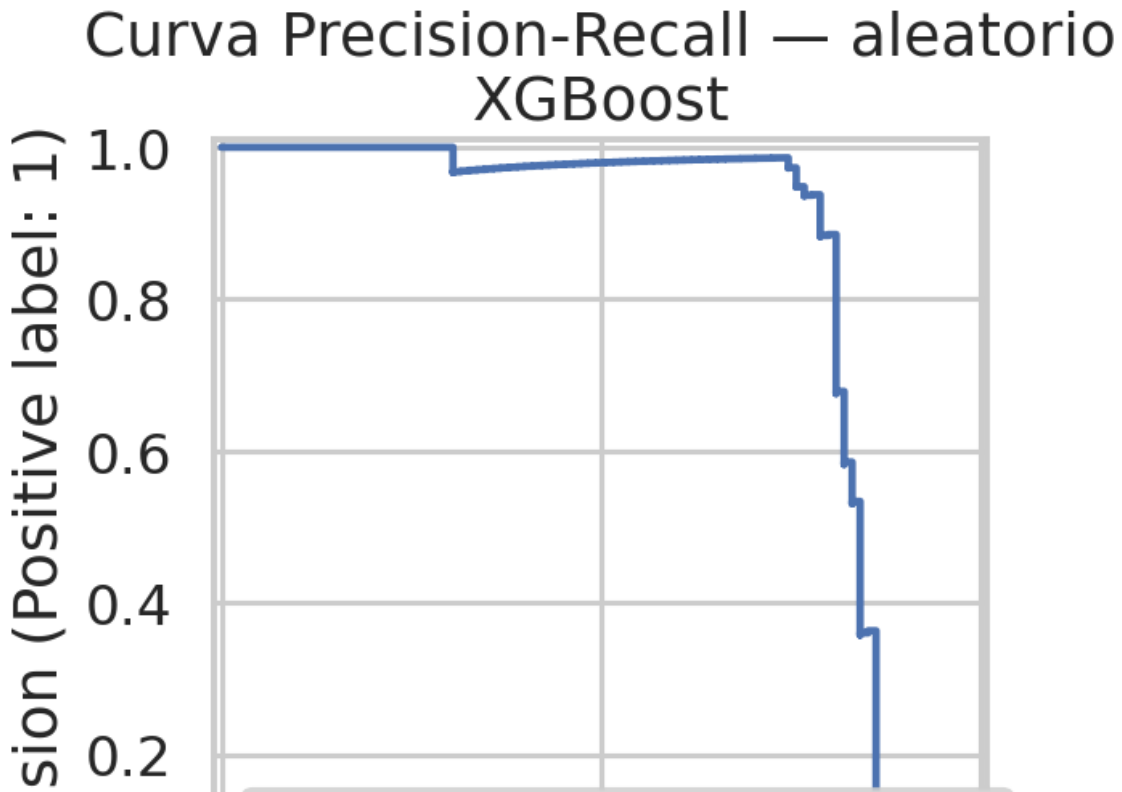
Métricas principales: PR-AUC, Recall, Precision (+ F1, ROC-AUC).

Negocio: captura Top-K y volumen de alertas por umbral.

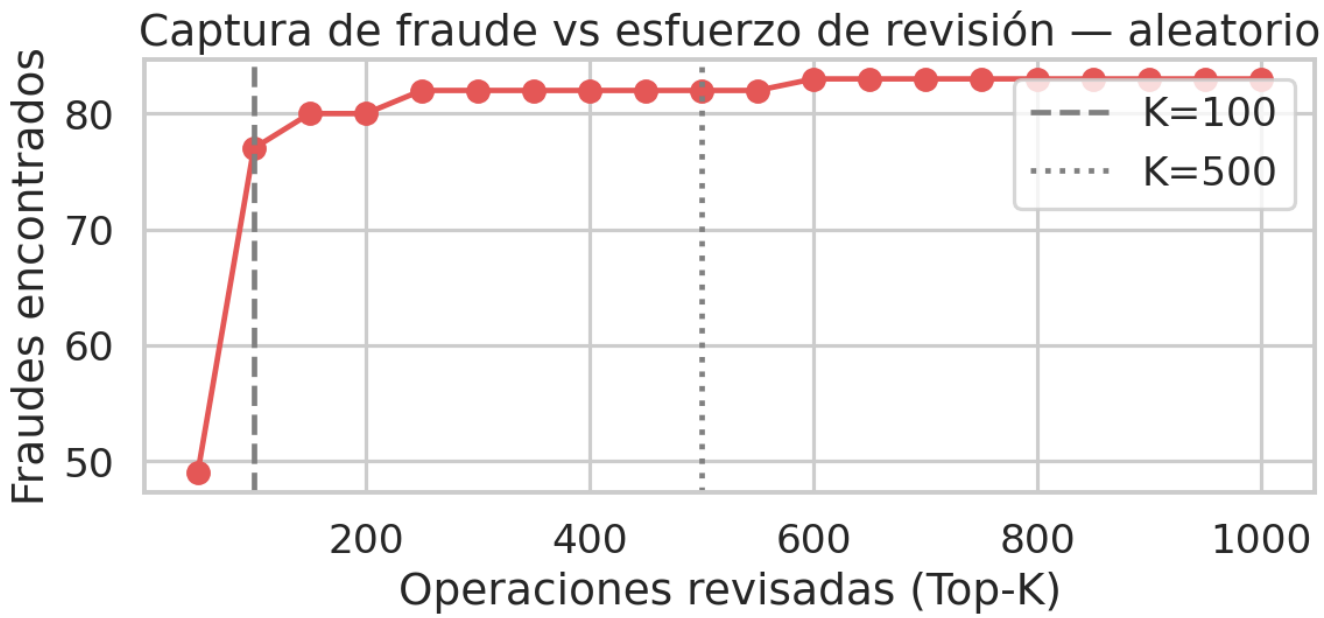
Validación: holdout estratificado 80/20 vs split temporal por Time.

Resultados clave — modelo: XGBoost

PR-AUC	Recall	Precision	F1
0.827	81.1%	86.5%	0.837



Métrica de negocio: ¿cuántos fraudes si revisamos Top-K?



Top-100 → 77 fraudes

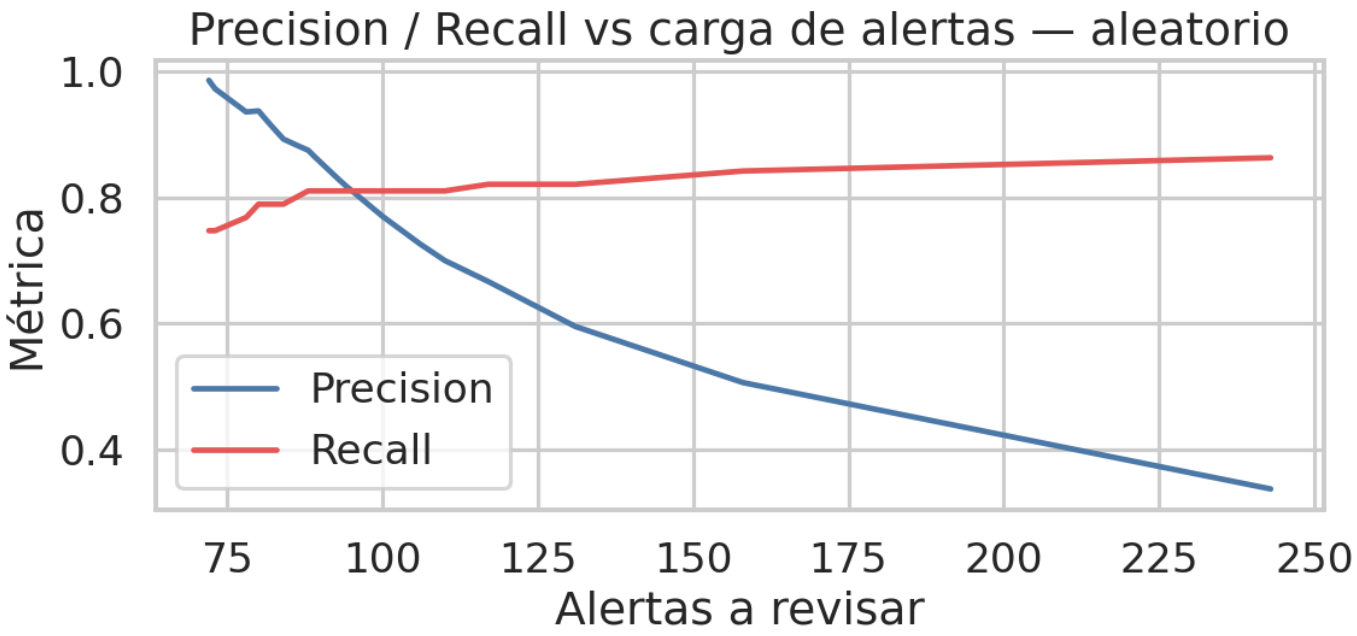
Precision@100 = 77.0%

Top-500 → 82 fraudes

Lift@500 = 98.0×

Traduce el score a una cola de revisión realista para el equipo.

No alcanza con FPR: mirar Precision y carga de revisión



FPR 5% sobre ~56,651 legítimas = miles de falsas alertas.

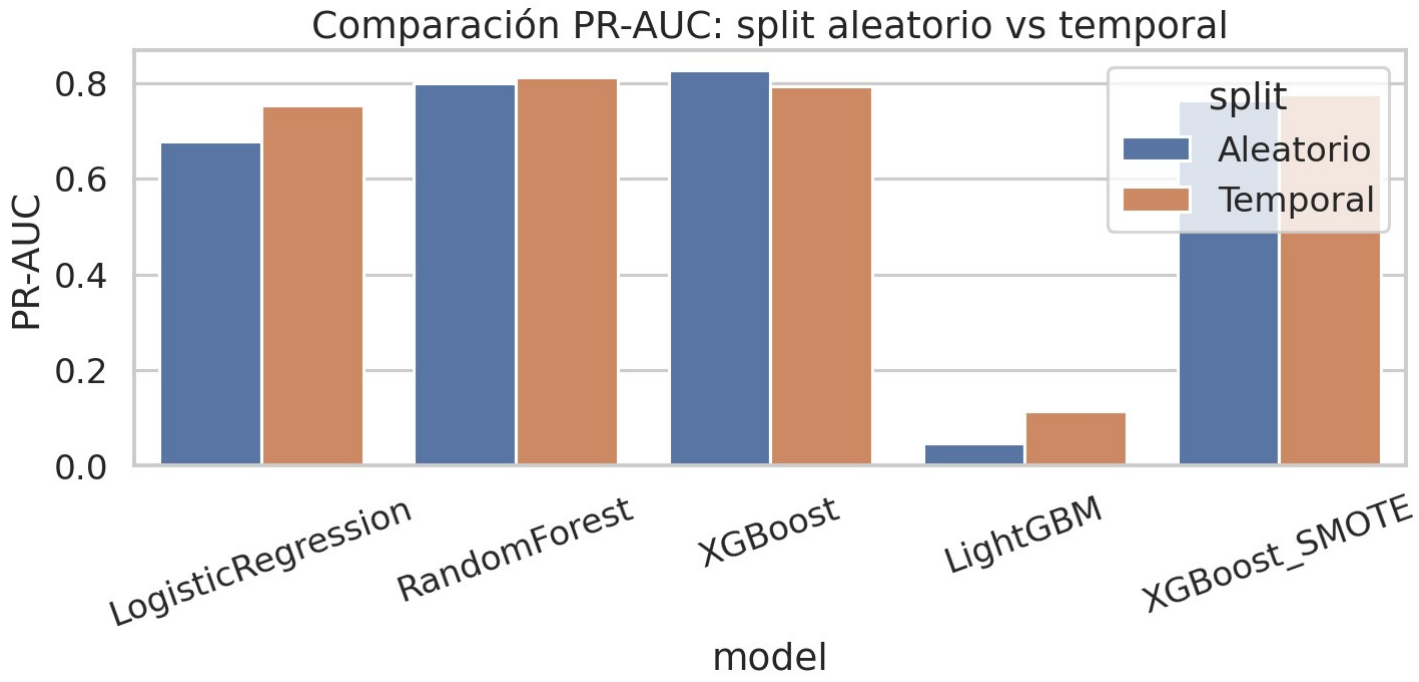
Umbral elegido: 0.55

Alertas a revisar: 88

Recall 81.1% · Precision 87.5%

TP=77 · FP=11 · FN=18

Validación temporal vs aleatoria



Aleatorio: mezcla pasado/futuro.

Temporal: entrena con anteriores, prueba con posteriores.

Mejor temporal: RandomForest

PR-AUC temporal: 0.813

Más realista para despliegue.

Impacto esperado

Prioriza la cola de revisión humana (Top-100 / Top-500).

Reduce fraudes no detectados vs reglas estáticas.

Evita saturar al equipo con miles de falsas alarmas.

Umbral = decisión de negocio explícita (Precision + capacidad).

Escalable a scoring batch / near real-time.

Riesgos, limitaciones y ética

Dataset de solo 2 días (2013): representatividad limitada.

Variables PCA dificultan explicación regulatoria.

Falso positivo = fricción al cliente; falso negativo = pérdida.

Datos anonimizados; sin PII; licencia ODbL.

Requiere monitoreo de drift y recalibración del umbral.

Conclusiones y próximos pasos

Modelo recomendado: XGBoost (mejor PR-AUC).

KPI técnicos: PR-AUC · Recall · Precision.

KPI de negocio: captura Top-100 / Top-500 y alertas revisables.

Validar siempre con esquema temporal antes de producción.

Próximos pasos: feedback del analista, drift monitoring, features adicionales.

Código + informe + esta presentación en el repositorio del Grupo 33.