DIPLOMADO EN CIENCIA DE DATOS Y ANÁLISIS AVANZADO

Unidad N° 9 — Proyecto Final Integrador

Detección de Fraude en Tarjetas de Crédito

Presentación Final del Proyecto — Grupo 33

Mariana Chaile · Eugenia Salcedo Aisa · Sol Kidonakis

Marco Garcia · Esteban Derghazarian

Octubre 2026

Índice

- 1. Resumen ejecutivo
- 2. Problema de negocio y objetivo
- 3. Datos y metodología (CRISP-DM)
- 4. Modelos evaluados y selección
- 5. Resultados clave (PR-AUC, Recall, Precision)
- 6. Métrica de negocio: captura Top-100 / Top-500
- 7. Umbral operativo y carga de revisión
- 8. Validación temporal vs aleatoria
- 9. Impacto, riesgos y ética
- 10. Conclusiones y recomendaciones

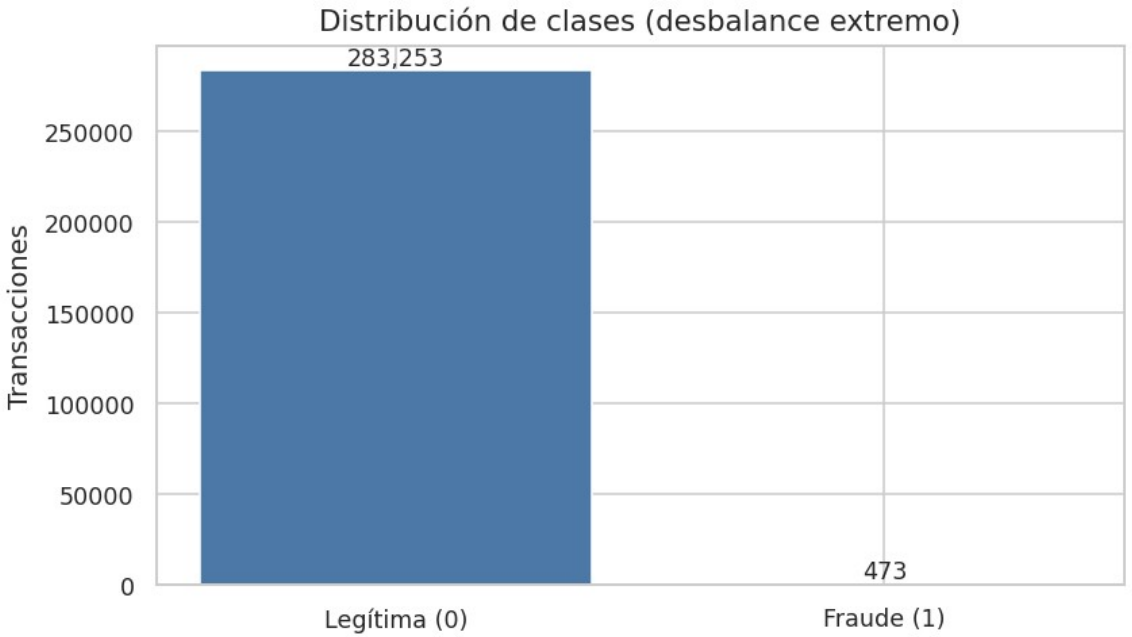
1. Resumen ejecutivo

- Problema: detectar fraude en un flujo con desbalance extremo (492 fraudes en 284.807 transacciones; 0,172 %).
- Solución: modelo supervisado XGBoost que prioriza una cola de revisión humana.
- Resultados clave (holdout aleatorio): PR-AUC 0.827 · Recall 81.1% · Precision 86.5%.
- Negocio: Top-100 → 77 fraudes; Top-500 → 82 fraudes (lift 98.0×).
- Operación: umbral 0.55 → solo 88 alertas (77 TP / 11 FP), frente a miles con un FPR del 5 %.
- Robustez: en validación temporal, RandomForest alcanza PR-AUC 0.813.

2. Problema de negocio y objetivo

- Audiencia: Prevención de Fraude / Gestión de Riesgo Crediticio.
- Objetivo medible: clasificar cada transacción (fraude vs legítima) maximizando detección y controlando alertas revisables.
- Hipótesis: patrones en monto, tiempo y componentes PCA superan reglas estáticas.
- KPI técnicos: PR-AUC, Recall y Precision (no Accuracy ni solo FPR).
- KPI de negocio: ¿cuántos fraudes encontramos si revisamos Top-100 o Top-500?
- Restricción crítica: con tan pocos fraudes, FPR ≤ 5 % generaría miles de falsas alertas.

3. Datos y metodología (CRISP-DM)



- Fuente: ULB / Kaggle (ODbL).
- Tras limpieza: 283,726 filas; 473 fraudes.
- Sin nulos; duplicados eliminados.
- Amount_log = log1p(Amount).
- Scaler de Time y Amount_log dentro del Pipeline (sin leakage).
- Validación: (A) aleatorio 80/20 estratificado; (B) temporal por Time.

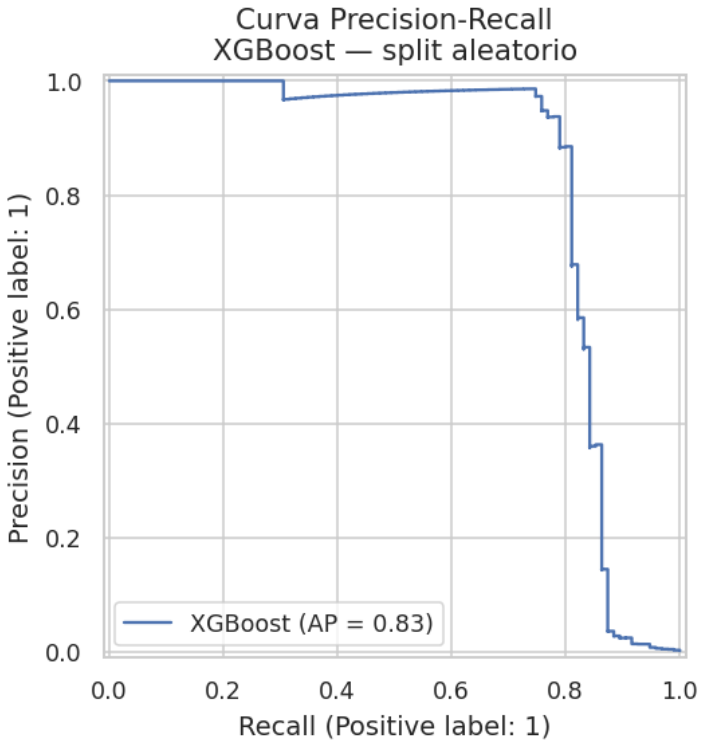
4. Modelos evaluados y criterio de selección

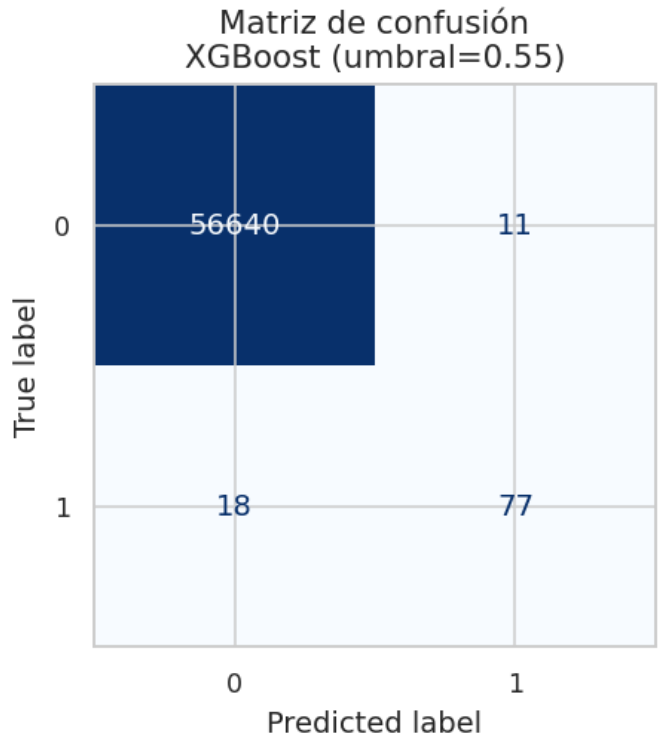
- Baseline: Regresión Logística (class_weight=balanced).
- Alternativas: Random Forest · XGBoost · LightGBM · XGBoost+SMOTE.
- Selección por PR-AUC (ranking bajo desbalance), con Recall/Precision y carga de alertas.
- Modelo elegido: XGBoost — mejor equilibrio detección / alertas útiles.

- LogisticRegression: PR-AUC 0.677 · R 87.4% · P 5.5%
- RandomForest: PR-AUC 0.799 · R 74.7% · P 89.9%
- XGBoost: PR-AUC 0.827 · R 81.1% · P 86.5% ← elegido
- LightGBM: PR-AUC 0.048 · R 76.8% · P 6.0%
- XGBoost_SMOTE: PR-AUC 0.765 · R 84.2% · P 7.9%

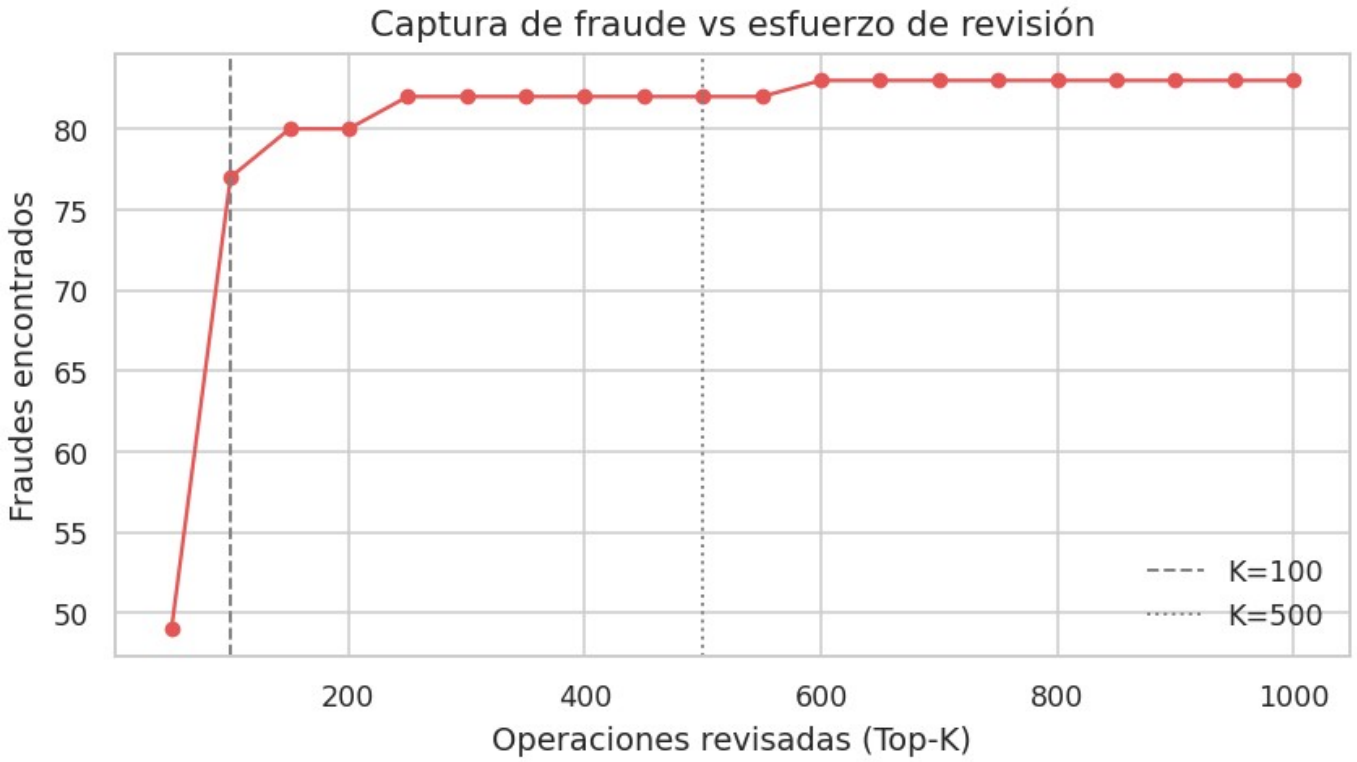
5. Resultados clave — holdout aleatorio

PR-AUC	Recall	Precision	F1
0.827	81.1%	86.5%	0.837



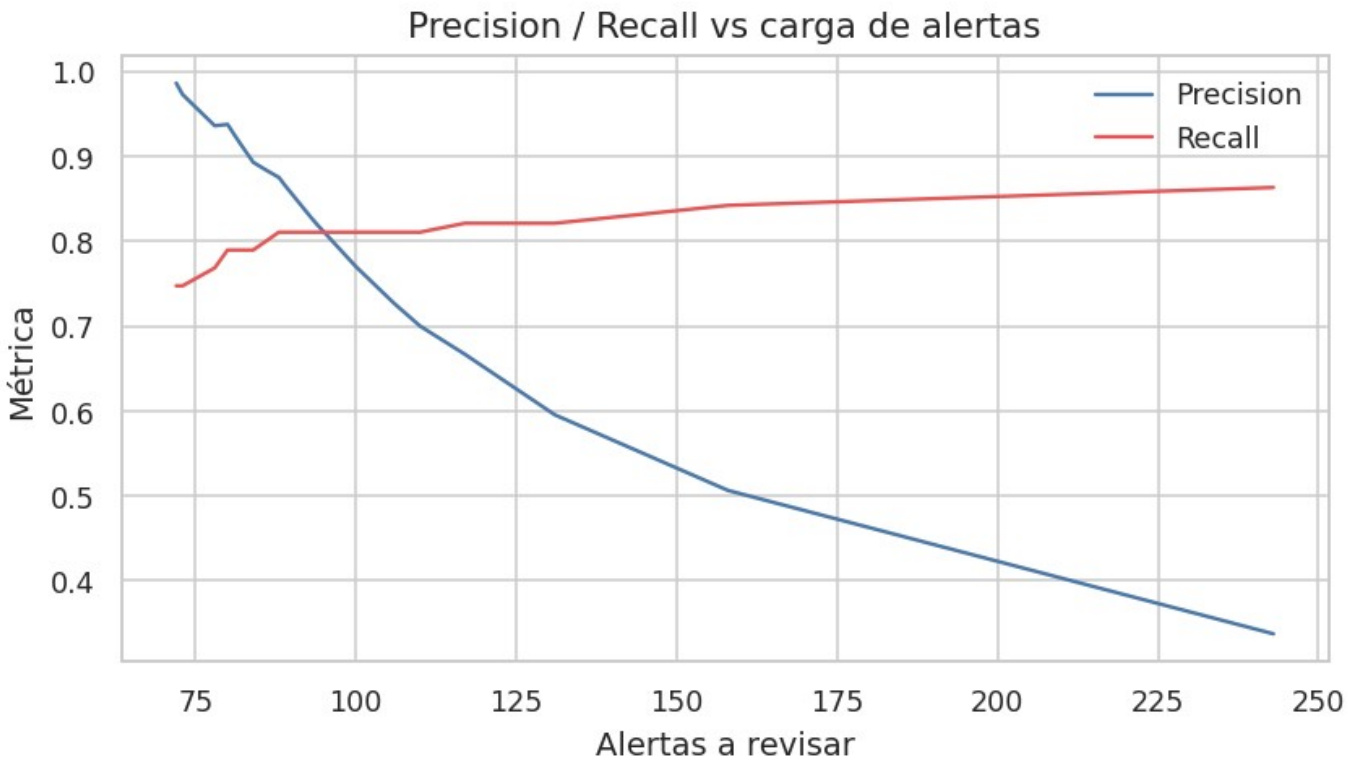


6. Métrica de negocio: si revisamos Top-K, ¿cuántos fraudes?



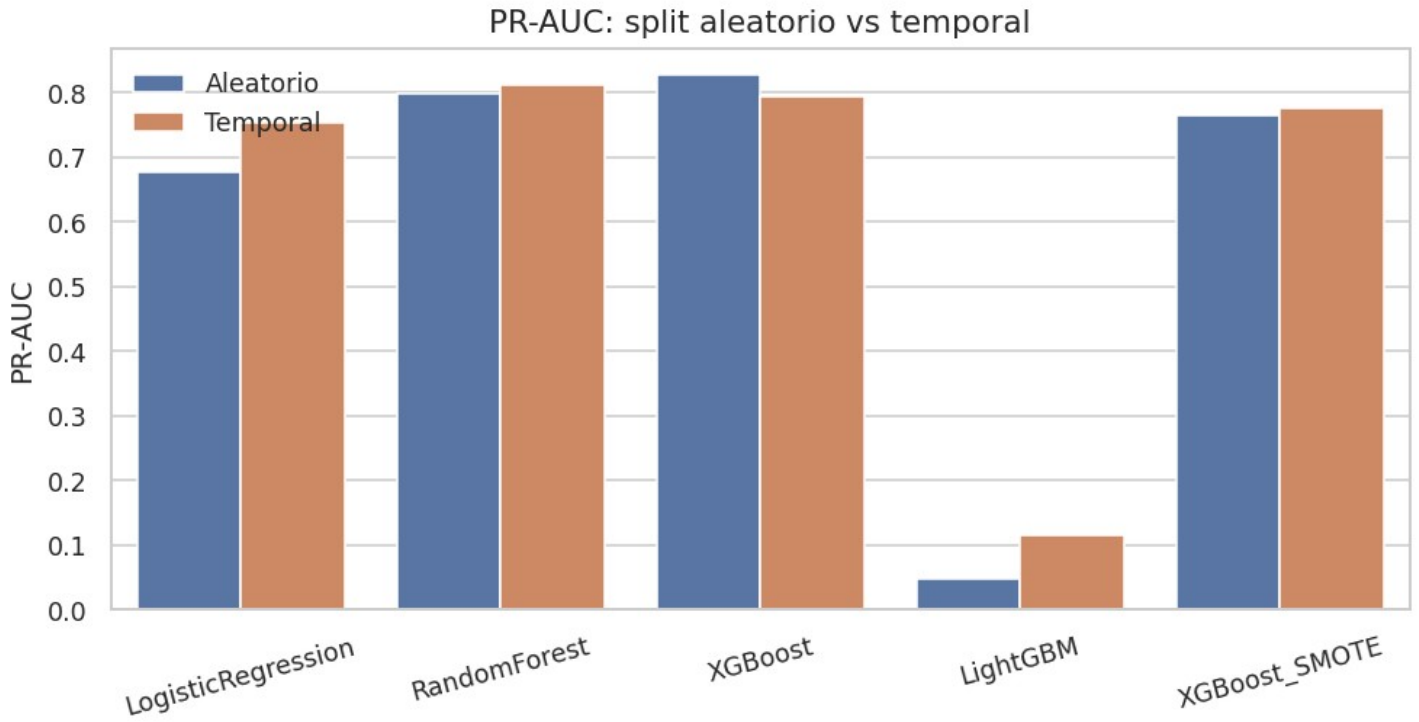
- Top-100 → 77 fraudes
- Precision@100 = 77.0%
- Recall@100 = 81.1%
- Top-500 → 82 fraudes
- Lift@500 = 98.0×
- El score ordena la cola de revisión del equipo.

7. Umbral operativo: Precision y carga real de alertas



- FPR 5 % ≈ 2,832 alertas falsas solo en el holdout.
- Umbral elegido: 0.55
- Alertas a revisar: 88
- Recall 81.1% · Precision 87.5%
- TP=77 · FP=11 · FN=18
- No alcanza con controlar FPR: hay que mirar Precision y volumen.

8. Validación temporal vs aleatoria



- Aleatorio: mezcla pasado y futuro.
- Temporal: entrena con anteriores, prueba con posteriores (más realista).
- Mejor temporal: RandomForest
- PR-AUC 0.813
- Recall 73.0% · Precision 94.7%
- Top-100 → 59 · Top-500 → 65

9. Impacto, riesgos y consideraciones éticas

- Impacto: prioriza la cola de revisión; reduce fraudes no detectados y el ruido operativo.
- Combinable con reglas existentes (ML como capa de priorización).
- Riesgos: dataset de 2 días (2013); PCA poco interpretable; posible drift.
- Ética: datos anonimizados (sin PII); falso positivo = fricción al cliente; falso negativo = pérdida financiera.
- El umbral es una decisión de negocio explícita, no un default técnico.
- Uso académico bajo licencia ODbL; despliegue real requiere supervisión humana.

10. Conclusiones y recomendaciones

- Recomendamos XGBoost como modelo candidato (mejor PR-AUC en holdout aleatorio).
- Reportar siempre PR-AUC, Recall, Precision y cantidad de alertas.
- Usar captura Top-100 / Top-500 como KPI operativo de la cola de revisión.
- Validar con esquema temporal antes de cualquier despliegue.
- Próximos pasos: feedback del analista, monitoreo de drift, features adicionales (dispositivo, geo, historial) y calibración de scores.
- Código reproducible en el repositorio GitHub del Grupo 33 (README + notebook).